

Machine Learning Pipeline Analysis for Improving Semiconductor Defect Detection Performance in Missing Value and Class Imbalanced Environments

NamHo Lee[†], MyungGeun Ji, HwanIl Yu, AhHyun Choi
Department of Industrial Engineering, Konkuk University

결측치 및 클래스 불균형 환경에서의 반도체 불량 검출 성능 향상을 위한 머신러닝 파이프라인 분석

이남호[†], 지명근, 유환일, 최아현
건국대학교 산업공학과

Semiconductor manufacturing data contain extensive missing values and severe class imbalance, making fault detection challenging. Model performance can vary significantly depending on the choice of imputation, balancing, feature selection, and classification methods. This study systematically analyzes the performance characteristics of machine learning pipeline components under missing and imbalanced environments and investigates the potential of missingness patterns as auxiliary information through Missing Indicators (M features). A total of 924 pipeline combinations based on the UCI SECOM dataset were evaluated using 9-fold cross-validation to prevent data leakage. F2-score, Recall, and True Negative Rate (TNR) were adopted as the primary evaluation metrics. Experimental results showed that the MICE / Raw / Mutual Information / Random Forest pipeline without M features achieved the best performance. Furthermore, in several pipeline configurations, the inclusion of Missing Indicators improved TNR and F2-score without degrading Recall, suggesting that missingness patterns can provide useful auxiliary information for fault detection under certain conditions.

Keywords: Semiconductor Fault Detection, Imbalanced Data, Missing Data, Machine Learning Pipeline, Missing Indicator, SECOM Dataset

1. 서 론

반도체 제조 산업은 초미세 공정과 고집적화 기술의 발전과 함께 공정 복잡도가 지속적으로 증가

하고 있다. 현대 반도체 생산 라인은 수백 단계 이상의 공정으로 구성되며, 각 단계에서는 온도, 압력, 유량, 전류와 같은 다양한 공정 변수들이 대규모 센서 네트워크를 통해 실시간으로 수집된다. 이

러한 공정 데이터는 생산 수율 향상과 품질 안정화를 위한 핵심 자산으로 활용되며, 최근에는 머신러닝 기반 불량 검출 기술에 대한 관심이 크게 증가하고 있다. 특히 공정 이상을 조기에 탐지하여 불량 발생을 최소화하는 것은 생산 수율과 제조비용에 직접적인 영향을 미치는 핵심 과제로 인식되고 있다.

그러나 실제 반도체 공정 데이터는 높은 차원성, 광범위한 결측치, 그리고 심각한 클래스 불균형 문제를 동시에 포함한다. 대표적인 공개 산업 데이터셋인 SECOM 데이터셋은 수백 개 이상의 센서 변수와 함께 다수의 결측값을 포함하고 있으며, 실제 불량 샘플 비율 또한 전체의 약 6% 수준에 불과하다. 이러한 특성은 일반적인 머신러닝 모델의 학습을 어렵게 만들며, 특히 다수 클래스에 편향된 예측으로 인해 실제로 중요한 불량 샘플 탐지 성능이 저하되는 문제를 초래한다.

이러한 문제를 해결하기 위해 결측치 대체(imputation), 클래스 불균형 처리(balancing), 특성 선택, 분류 모델을 조합하는 다양한 파이프라인이 제안되어 왔다. 특히 SECOM 환경에서는 In-painting KNN 기반 대체와 SMOTE 기반 클래스 불균형 처리를 결합하고, 데이터 누출을 방지하는 파이프라인 기반 검증 구조를 적용했을 때 불량 검출(fault detection) 성능이 향상됨이 보고되었다 [15]. 그러나 기존 연구는 결측치의 제거 또는 추정 기반 복원에 초점을 두어, 결측 발생 패턴 자체가 내포하는 정보적 의미는 상대적으로 제한적으로 다루어져 왔다.

실제 반도체 공정 환경에서 센서 결측은 단순한 무작위 오류라기보다 설비 이상, 공정 불안정, 측정 실패 등과 연관되어 발생할 가능성이 존재한다. 즉 결측 발생 자체가 공정 이상 상태와 관련된 정보를 포함할 가능성이 있으며, 이러한 정보는 불량 검출 과정에서 보조적인 역할을 수행할 수 있다. 이에 결측 여부를 이진 변수 형태로 표현한 결측 지시변수(Missing Indicator, M_{ij})를 도입하고, 기존 공정 변수와 결합하거나 독립적으로 활용하였을 때 불량 검출 성능에 어떠한 영향을 미치는지를 분석하고자 하였다.

특정 단일 모델의 성능 최적화보다, 결측 및 클래스 불균형 환경에서 머신러닝 파이프라인 구성 요소별 성능 특성 분석에 중점을 두었다. 이를 위해 결측치 대체 방법, 클래스 불균형 처리 여부, 특성

선택 기법, 분류 모델을 조합한 총 924개의 파이프라인을 구성하였으며, 모든 실험은 데이터 누출을 방지하기 위해 K-Fold 기반 파이프라인 내부에서 수행하였다. 또한 F2-score, Recall, TNR(True Negative Rate)을 중심으로 불량 검출 성능을 평가함으로써, 불량 탐지 성능과 정상 샘플 구분 성능 간의 균형을 함께 고려하였다.

주요 기여는 다음과 같다. 첫째, 결측 및 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 다양한 머신러닝 파이프라인 조합을 체계적으로 비교·분석하였다. 둘째, 결측 여부 자체를 나타내는 결측지시변수를 도입하여 결측 패턴의 정보적 활용 가능성을 실험적으로 검증하였다. 셋째, 단순 최고 성능 조합뿐 아니라 생존 파이프라인(surviving pipeline) 기반 분석을 통해 각 파이프라인 구성 요소의 일반적인 성능 경향과 안정성을 함께 분석하였다.

논문의 구성은 다음과 같다. 2장에서는 관련 이론 및 선행 연구를 고찰하고, 3장에서는 실험 파이프라인과 데이터 처리 과정을 설명한다. 4장에서는 실험 결과와 성능 분석을 제시하며, 마지막으로 5장에서는 결론 및 향후 연구 방향을 논의한다.

2. 선행 연구

반도체 제조 공정의 이상 감지는 고차원·불균형 공정 데이터를 다루는 기계학습 문제로 발전해 왔다. 이러한 연구 동향을 공정 이상 감지를 위한 전처리 파이프라인, 결측치 처리 및 결측 지시변수의 활용, 클래스 불균형 대응의 세 가지 관점에서 고찰하고, 기존 연구의 한계와 차별성을 도출한다.

2.1 반도체 공정 데이터의 전처리와 결측 정보 활용

반도체 제조 공정은 수백 단계의 미세 공정으로 구성되며, 각 단계에서 온도·압력 등 수천 개의 센서 변수가 실시간으로 수집된다. 이러한 고차원·불균형 데이터로부터 불량을 조기에 탐지하는 문제는 수율 향상과 직결되며, SECOM 데이터셋 [8]의 공개 이후 활발히 연구되어 왔다. SECOM은 약 6.7%의 결측치와 약 1:14의 극단적 클래스 불균형을 동반하여 불균형·결측 환경의 분류 방법론을 검

증하는 벤치마크로 자리잡았으며, 단일 모델보다 복수 분류기를 결합하는 접근이 공정 이상 감지에 효과적임이 보고되었다 [18]. 이처럼 결측과 불균형이 공존하는 데이터에서는 분류기 자체보다 전처리 파이프라인의 설계가 성능을 좌우하며, 그 과정에서 핵심적으로 다루어진 쟁점은 데이터 누출(Data Leakage)의 방지였다. 정제·대치·균형화·특성 선택·분류로 이어지는 다단계 파이프라인에서는 훈련·테스트 분할 이후에 전처리를 수행해야 정보 누출을 막을 수 있다는 점이 일관되게 강조되어 왔다 [9][15]. 이러한 구조 위에서 기댓값 최대화(EM) 기반 대치와 오버샘플링의 결합 [7], ADASYN 오버샘플링과 MaxAbs 스케일링을 SVM과 결합하는 접근 [9] 등이 탐색되며 이상 감지 성능이 향상되어 왔다. 전처리의 한 축인 결측치 처리는 단순한 데이터 복원을 넘어 중요한 쟁점을 제기한다. 산업 현장의 센서 결측은 설비 이상이나 통신 불량 등 물리적 요인과 직결되어 단순 무작위 누락(MCAR)이 아닌 비무작위 결측(MNAR)의 특성을 띠는 경우가 많으며 [13], 전통적 접근은 평균 대치나 KNN 기반 기법으로 완전한 데이터 행렬을 복원하는 데 초점을 두었다. 그러나 예측 모형의 관점에서는 결측치 처리 전략을 기술·인과 추론 목적과 다르게 설계해야 하며, 결측이 발생했다는 사실 자체가 잠재적 상태 정보를 내포할 수 있다 [17].

결측값 처리 방식은 분류 모델의 예측 성능에 영향을 미치며[14], 특히 결측 여부를 이진 특성으로 표현하는 결측지시변수는 정보성 결측이 존재하는 조건에서 예측 성능 향상에 기여할 수 있다[19]. 다만 종단(longitudinal) 데이터 환경에서는 결측지시변수의 효과가 일관된 성능 향상으로 나타나지는 않았으며, 전체 성능이나 대치 정확도에 큰 차이를 보이지 않았다는 결과도 보고되었다[4]. 고차원 환경에서는 정보성 결측(Informative Missingness) 패턴을 효과적으로 인코딩하여 선형·비선형 모델의 강건성과 예측력을 동시에 높일 수 있음이 규명되었으며 [19], 비무작위 결측 환경에서는 결측 메커니즘에 대한 가정이 대치 성능에 직접적인 영향을 미치는 것으로 나타났다 [11].

2.2 클래스 불균형 대응 및 앙상블 분류 모델

반도체 공정과 같이 양품 대비 불량률의 비율이 극


히 낮은 환경에서는 모델이 다수 클래스(정상)로 예측을 편향하는 문제가 발생하며, 이를 완화하기 위해 단순 정확도 중심의 평가와 고정된 분류 임계값을 재검토하고, 데이터 분포와 오류 비용을 고려한 샘플링 전략을 설계할 필요가 있다 [12]. 표준적으로 활용되는 SMOTE 기반 소수 클래스 합성 기법 [2] 은 불균형 완화에 효과적이지만, 고차원 노이즈 데이터에 부적절하게 적용될 경우 과적합을 유발할 수 있다.

이에 따라 최근 연구들은 샘플링 기법과 함께 강력한 특성 선택 및 앙상블 분류기를 결합하는 방식을 채택하고 있다. 다수의 특성 선택 기법을 결합한 앙상블 투표(Voting)와 SMOTE를 조합하여 핵심 변수를 추출하고 이를 XGBoost에 적용함으로써 클래스 분리도와 소수 클래스 탐지력(Recall)을 크게 개선한 사례가 대표적이다 [5]. 이는 산업도메인에서 불량을 놓치는 비용(Type II Error)이 오탐 비용(Type I Error)보다 훨씬 크다는 점에서, 정밀도보다 재현율을 중심으로 한 앙상블 모델링이 중요함을 시사한다.

2.3 기존 연구의 한계 및 차별성

상기 고찰한 바와 같이, 선행 연구들은 고차원 반도체 데이터의 특성을 반영하여 결측치 대치, 오버샘플링, 분류 알고리즘을 조합하는 파이프라인 연구로 발전해 왔다. 그러나 대다수는 결측치 대치 방식의 고도화에 집중할 뿐, 결측 메커니즘 자체가 지니는 정보량(MNAR)을 결측지시변수 형태로 분류 모델에 직접 통합하여 그 효과를 체계적으로 규명한 연구는 부족하다. 더욱이 대치 정확도의 향상이 반드시 후속 예측 성능 개선으로 이어지지 않으며 [6], AutoML 환경에서는 정교한 대치 기법 없이도 경쟁력 있는 예측 성능이 가능하다는 점 [10]이 보고되면서, 대치 방식의 고도화보다 결측 패턴 자체의 정보적 활용을 탐색할 필요성이 제기되고 있다.

이에 데이터 누출 방지 교차검증 구조 [9][15]를 기본 골격으로 채택하되, 기존 연구를 세 가지 측면에서 확장한다. 첫째, 평균 대치뿐 아니라 MICE, MissForest 등 다중 대치 기법으로 범위를 넓힌다. 둘째, 각 대치 조건에 결측 지시변수를 결합하여 결측 패턴 정보의 독립적 기여도를 실증한다. 셋째, 분류 모델을 XGBoost, HGB(Histogram-based



<Figure 1> Overall Experimental Design and Pipeline Framework

Gradient Boosting) 등 희소 행렬(Sparse Matrix) 처리에 강점이 있는 부스팅 계열로 확장하여, 결측 패턴과 비선형 공정 변수 간의 결합 효과를 분석한다.

3. 연구방법론

3.1 전체 실험 파이프라인 및 교차 검증 설계

연구가 제안하는 분류 파이프라인은 데이터 정제, 결측치 대체, 클래스 불균형 처리, 특성 선택, 분류(Classification)의 5단계로 구성된다. 각 단계별로 복수의 방법론을 교차 적용하여 총 924개(11×2×7×6)의 파이프라인 조합을 생성하고 성능을 비교 분석하였다. 모델 학습 과정에서 발생할 수 있는 데이터 누출을 원천적으로 방지하기 위해 K-Fold 교차 검증(K=9) 구조를 채택하였으며, 결측치 대체를 위한 통계량 산출, SMOTE 기반의 합성 데이터 생성, 특성 선택을 위한 p-value 산출 등 모든 전처리 과정은 교차 검증 루프 내부에서 훈련 데이터만을 기준으로 수행하였다. 산출된 기준을 검증 데이터에 동일하게 적용하여 모델의 일반화 성능을 객관적으로 평가하였다. 각 방법론에 대한 구체적인 하이퍼파라미터 셋업 및 튜닝 과정은 4.1절 실험 환경 및 하이퍼파라미터 설정에서 상세히 다룬다.

<Table 1> Processing Methods and Total Number of Combinations for Each Pipeline Stage

Step	List of processing methods	Number of methods
1. Imputation	Raw, Raw+M, Mean, Mean+M, Inpainting KNN, Inpainting KNN+M, MICE, MICE+M, MissForest, MissForest+M, M_only	11
2. Balancing	Raw(Not applied), SMOTE	2
3. Feature selection	chi2, f_classif, mutual_info, FPR, FDR, FWE, Raw(Not applied)	7
4. Classification model	KNN, SVM, Logistic Regression, Random Forest, XGBoost, HGB	6
Total number of combinations	$11 \times 2 \times 7 \times 6$	924

3.2 데이터 정제 및 결측 지시변수 생성

수집된 반도체 공정 원본 데이터에 대해 두 단계의 정제를 수행하여 분석의 신뢰성을 확보하였다. 첫째, 50% 이상의 결측률을 가진 특성(Feature)은 유의미한 정보 복원이 불가능하다고 판단하여 제거하였다. 둘째, 분산이 0.05 이하인 특성은 모든 샘플에서 유사한 값을 가져 불량 검출에 기여하지 못하므로 추가로 제거하였다. 이 과정을 거친 데이터를 기준 데이터(Raw)로 정의하였다.

이후, 정제된 데이터에 존재하는 결측 패턴 자체가 공정 이상의 유의미한 신호 (MNAR: Missing Not At Random)일 수 있다는 가설을 검증하기 위해 결측지시변수를 도입하였다. 임의의 센서 변수 x_{ij} 에 대한 M_{ij} 는 결측 발생 여부에 따라 1 또는 0의 이진 값을 갖도록 생성된다. 결측지시변수는 실험 설계에 기반하여 세 가지 조건으로 모델에 투입되었다.

<Table 2> Conditions for Applying Missing Indicator Variables (M Feature)

Application conditions	Data configuration
Raw	Use only the original variables on which only missing values have been imputed
Raw + M	Combine the M_Features with the original variable in the column direction
M_only	Use only M_Features as independent input variables without original variables

3.3 결측치 대체 및 클래스 불균형 처리

데이터 내 잔존하는 결측치를 처리하기 위해 단순 대체부터 다중 대체에 이르는 4가지 대체 기법을 파이프라인에 적용하였다. 비교의 기준점이 되는 평균 대체(Mean Imputation)를 비롯하여, 결측값의 신뢰도와 이웃 샘플 간의 거리를 기반으로 결측치를 추정하는 In-painting KNN, 변수 간의 조건부 분포를 반복적으로 모델링하는 MICE(Multiple Imputation by Chained Equations), 그리고 비선형적 관계 포착에 강점이 있는 Random Forest 기반의 MissForest를 활용하였다. 각 대체 기법은 앞서 정의한 M 피처 적용

조건과 결합되어 총 11가지의 대체 조건으로 확장된다.

반도체 공정 데이터의 극단적인 클래스 불균형 (양품 대비 불량률의 극소수 분포)을 해소하기 위해 오버샘플링 기법인 SMOTE(Synthetic Minority Over-sampling Technique)를 적용하였다. SMOTE 적용 조건과 미적용(Raw) 조건을 비교하여 데이터 균형화가 불량 검출 성능에 미치는 영향을 평가하였다.

3.4 특성 선택(Feature Selection)

고차원 센서 데이터에 포함된 잡음(Noise) 변수를 제거하고 모델의 학습 효율을 높이기 위해 단변량 통계 및 유의성 검정에 기반한 6가지 특성 선택 기법을 적용하였다. 범주형 목표 변수와의 연관성을 평가하는 카이제곱 검정(χ^2 test), 연속형 변수의 클래스 간 분산을 비교하는 ANOVA F-검정 (f_classif), 변수 간의 비선형적 의존성까지 포착하는 상호정보량(Mutual Information) 기법을 활용하였다. 또한, 다중 검정 오류를 통제하기 위해 위양성률 통제(FPR), 위발견률 통제(FDR), 집단오류를 통제(FWE) 방식을 함께 적용하였다. 특성 선택을 전혀 수행하지 않은 조건(Raw)을 포함하여 총 7가지 조건을 비교하였다.

3.5 분류 모델 및 성능 평가

M 피처의 결합 효과를 다각도로 분석하기 위해 선형 및 비선형 기계학습 모델 6종을 파이프라인의 최종 분류기로 구성하였다. 비교적 단순한 결정 경계를 가지는 KNN, 서포트 벡터 머신(SVM), 로지스틱 회귀(Logistic Regression)와 함께, 고차원 데이터 처리에 강점이 있는 앙상블/부스팅 계열의 Random Forest, XGBoost, HGB를 평가 대상에 포함하였다. 특히 불균형 환경에서 소수 클래스 탐지력을 높이기 위해 검증 데이터 기반의 임계값 이동(Threshold Moving) 전략을 적용하였다.

파이프라인의 성능은 모델이 실제 불량을 놓치지 않고 탐지하는 능력을 최우선으로 고려하여 재현율(Recall)과 F2-score를 핵심 평가지표로 사용하였다. 또한, 과도한 오탐(False Alarm)으로 인한 현장 적용성 저하를 방지하기 위해 진음성률을 보조 지표로 모니터링하였다. 아울러 실효성 있는 파

이프라인의 선별을 위해 전체 924개 조합 중 $TNR \geq 0.5$ 및 $Recall \geq 0.6$ 을 동시에 만족하는 조합만을 '생존 파이프라인'으로 정의하였다. $TNR \geq 0.5$ 는 모델이 정상 샘플의 절반 이상을 올바르게 구분하는 최소 수준으로, 이를 하회하는 모델은 사실상 정상 샘플 대부분을 불량으로 오분류하는 극단적 편향 모델로 판단하여 제외하였다. $Recall \geq 0.6$ 은 실제 불량 샘플의 60% 이상을 탐지하는 최소 실용 수준으로, 반도체 공정에서 불량 미탐지(Type II Error)의 비용이 오탐(Type I Error)보다 큰 도메인 특성을 반영한 기준이다.

4. 실험 결과 및 분석

생존 기준을 만족한 파이프라인은 총 137개로 확인되었으며, 이를 기준으로 각 파이프라인 구성 요소별 성능 특성을 분석하였다.

4.1 실험 환경 및 하이퍼파라미터 설정

제안한 파이프라인의 객관적인 성능 평가와 데이터 누출 방지를 위해 모든 실험을 K-Fold(K=9) 교차 검증 구조 내에서 수행하였다. 각 전처리 단계 및 분류 모델의 하이퍼파라미터는 데이터 규모와 클래스 불균형 비율을 고려하여 설정하였다. 파

이프라인 구성 요소 간 공정한 비교를 위해 하이퍼파라미터는 각 모델의 기본값 또는 불균형 대응에 최소한으로 필요한 값으로 고정하였으며, 모델 자체의 최적화보다 전처리 조합의 영향력 분석에 초점을 두었다.

결측치 대체 기법 중 평균 대체는 각 훈련 폴드의 열별 평균값을 적용하였고, In-painting KNN은 이웃 수(K)를 5로 설정하였다. 다중 대체법인 MICE와 MissForest는 학습의 안정성을 위해 최대 반복 횟수(max_iter)를 10으로, MissForest 내부 RF의 트리 수(n_estimators)는 100으로 고정하였다. 클래스 불균형 처리를 위한 SMOTE 역시 합성 샘플 생성 시 참조하는 이웃 수를 5로 설정하고, 훈련 집합 내 양품·불량 비율이 1:1이 되도록 지정하였다. 특성 선택 기법 중 단변량 통계 기반 기법(χ^2 , f_classif, mutual_info)은 교차 검증 루프 내에서 최적의 특성 수를 탐색하였으며, 통계적 유의성 기반 기법(FPR, FDR, FWE)은 유의 수준(α)을 0.05로 일괄 고정하였다.

최종 분류기 6종에 대한 파라미터는 각 모델의 기본 특성을 반영하되 클래스 불균형에 대응하도록 구성하였다. 선형 모델(Logistic Regression, SVM)과 앙상블 모델(Random Forest, HGB)에는 클래스 빈도의 역수에 비례하는 class_weight='balanced' 가중치를 부여하였다.

XGBoost의 경우 각 폴드마다 '정상 샘플 수 / 불

<Table 3> Setting key parameters by classification model

Model	Num. of neighbors	Kernel Function	Regularization Parameter	Max Num. of Iterations	Class weight	Num. of estimators	Learning rate	Max-Tree depth	Positive Class Weight
KNN	5 (Default)	N/A	N/A	N/A	N/A	N/A	N/A	N/A	N/A
SVM	N/A	RBF	1	N/A	N/A	N/A	N/A	N/A	N/A
Logistic Regression	N/A	N/A	1	10000	balanced	N/A	N/A	N/A	N/A
Random Forest	N/A	N/A	N/A	N/A	balanced	100	N/A	N/A	N/A
XGBoost	N/A	N/A	N/A	N/A	N/A	100	0.1	3	inverse class ratio : normal
HGB	N/A	N/A	N/A	100	balanced	N/A	0.1	None	N/A

량 샘플 수'를 scale_pos_weight로 동적 계산하여 불량 클래스에 대한 손실 가중치를 상향 조정하였다. 또한 판정 임계값(0.5)을 그대로 사용할 경우 소수 클래스 탐지 성능이 저하되는 것을 막기 위해, [0.01, 0.99] 구간을 0.01 단위로 탐색하여 검증 폴드 상에서 F2-score를 최대화하는 최적 임계값(Threshold Moving)을 도출하였다. SVM은 비선형 결정 경계를 효과적으로 학습하기 위해 RBF(Radial Basis Function) 커널을 적용하였으며, 정규화 파라미터(C)는 기본값인 1로 설정하였다. 로지스틱 회귀는 클래스 불균형 환경에서도 최적화 과정이 충분히 수렴할 수 있도록 최대 반복 횟수(max_iter)를 10000으로 설정하였다. RF와 XGBoost는 예측 안정성과 과적합 완화를 위해 트리 수(n_estimators)를 100으로 고정하였다. 특히 XGBoost는 안정적인 부스팅 학습을 위해 학습률(learning_rate)을 0.1로 설정하고, 과도한 모델 복잡도를 방지하기 위해 최대 트리 깊이(max_depth)를 3으로 제한하였다. HGB는 안정적인 수렴을 위해 max_iter=100, learning_rate=0.1을 적용하였다.

4.2 결측치 대치 방법별 성능 비교

결측치 대치 방법에 따른 불량 검출 성능 차이를 분석하였다. 해당 분석은 동일 대치 조건을 공유하는 생존 파이프라인들의 평균 성능을 비교한 것으로, 특정 조합의 단일 최고 성능을 비교한 후속 내용과는 분석 단위가 다르다.

결측치시변수만 사용한 조합(M_only) 15개는 원본 특성을 사용하지 않고 결측 여부 정보만을 사용하는 별도 분석 대상이므로, 대치 비교에서는 이를 제외하였다. 따라서 대치 방법별 성능 비교는 원본 특성 또는 원본 특성에 결측치시변수를 추가한 경우를 사용하는 122개의 생존 파이프라인을 대상으로 수행하였다.

<Table 4> Top 3 Imputation Pipelines in Surviving Pipelines

	imputation	F2	Recall	TNR
1	Mean_M	0.3340	0.6797	0.6198
2	Missforest	0.3259	0.6510	0.6289
3	Mean	0.3237	0.6617	0.6149

대치 조건별 성능을 비교한 결과 <Table 4>,

Mean_M 조합이 평균 F2-score 0.3340으로 가장 높은 성능을 보였다. Mean_M은 Recall 0.6797, TNR 0.6198을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 안정적인 결과를 나타냈다. 이를 통해 먼저 단순 평균 대치 방식에 결측치시변수를 추가하는 것이 일부 조건에서는 결측 정보의 보조적 효과를 통해 성능 향상에 기여하였음을 확인하였다. 두 번째로 높은 성능을 보인 MissForest는 평균 F2-score 0.3259, TNR 0.6289를 기록하여 정상 샘플 구분 측면에서 안정적이었다. 세 번째로 높은 성능을 보인 Mean은 평균 F2-score 0.3237, Recall 0.6617, TNR 0.6149을 기록하였는데, 이는 복잡한 대치 방법이 항상 높은 성능을 보장하는 것은 아니며 단순 평균 대치도 특정 특성 선택·모델 조합에서는 충분히 경쟁력 있는 성능을 낼 수 있음을 시사한다. 종합하면 Mean_M이 가장 높은 평균 F2-score를 기록했다는 점은, 결측치시변수가 모든 조합에서 일관되게 효과적이지는 않으나 특정 대치 조건에서는 성능 향상에 기여할 수 있음을 보여준다.

4.3 SMOTE 적용여부에 따른 성능비교


클래스 불균형 문제를 완화하기 위한 SMOTE 적용 여부가 불량 검출 성능에 미치는 영향을 분석하였다.

<Table 5> Performance Comparison According to SMOTE Application in Surviving Pipelines

Balancing	F2	Recall	TNR
SMOTE	0.3249	0.6688	0.6081
Raw	0.3214	0.6644	0.6099

SMOTE 적용 여부에 따른 성능을 비교한 결과 <Table 5>, SMOTE를 적용한 조합은 평균 F2-score 0.3249로 Raw 조합의 0.3214보다 소폭 높은 성능을 보였다. Recall 역시 SMOTE 적용 조합에서 0.6688로 나타나 Raw의 0.6644보다 약간 높았다. 해당 결과는 소수 클래스인 불량 샘플을 보강하는 과정이 불량 검출 성능 향상에 일정 부분 기여하였음을 의미한다.

다만 TNR은 SMOTE 적용 조합에서 0.6081, 균형화 기법을 적용하지 않은 조합에서 0.6099로 거



<Figure 2> Component-wise Performance Comparison in Surviving Pipelines (Top 3)

의 유사하게 나타났다. 이는 생존 파이프라인만을 대상으로 할 경우, SMOTE 적용 여부에 따른 정상 샘플 구분 성능 차이가 크지 않음을 보여주었다.

종합적으로 SMOTE는 생존 파이프라인 내에서 F2-score, Recall을 소폭 향상시키는 경향을 보였으나, 그 차이는 크지 않았다. 따라서 SMOTE는 불량 검출 성능 향상에 유효한 클래스 불균형 처리 전략이지만, 성능 향상 폭은 대치, 특성 선택, 모델 조합에 따라 제한적으로 나타나는 것으로 해석된다.

4.4 특성 선택 방법별 성능 비교

<Table 6> Top 3 Feature Selection Strategies in Surviving Pipelines

	feature selection	F2	Recall	TNR
1	f_classif	0.3462	0.6869	0.6399
2	FPR	0.3415	0.6650	0.6484
3	Raw	0.3221	0.7106	0.5694

특성 선택 방법별 성능을 비교한 결과 <Table 6>, f_classif 기반 변수 선택 방식이 평균 F2-score 0.3462로 가장 높은 성능을 보였다. f_classif는 Recall 0.6869, TNR 0.6399를 기록하여 불량 검출 성능과 정상 샘플 구분 성능 모두 비교적 안정적이었다. 두 번째로 높은 성능을 보인 FPR 방식은 평균 F2-score 0.3415를 기록하였으며, TNR은 0.6484로 상위 3개 방법 중 가장 높아, 불량 검출 성능을 유지하면서도 정상 샘플을 구분하는 데 비교적 효과적으로 작동했음을 의미한다. 별도의 특

성 선택을 적용하지 않은 Raw는 평균 F2-score 0.3221로 세 번째에 위치하였으며, 특히 Recall은 0.7106로 가장 높게 나타나 모든 변수를 유지하는 방식이 불량 샘플 탐지에 유리할 수 있음을 보여준다. 그러나 TNR은 0.5694로 f_classif 및 FPR보다 낮아, 정상 샘플 오분류 가능성이 상대적으로 큰 것으로 해석된다. 실제 특성 선택 기법만을 기준으로 보면 Raw를 제외하고 f_classif, FPR, mutual_info 순으로 높은 성능을 보였다. 그러나 전체 파이프라인 구성 전략 관점에서는 Raw 역시 특성 선택 미적용 기준선으로 의미가 있으며, f_classif와 FPR이 F2-score와 TNR의 균형 측면에서 가장 안정적인 변수 선택 방식으로 확인되었다.

4.5 모델별 성능 비교

<Table 7> Top 3 Models in Surviving Pipelines

	model	F2	Recall	TNR
1	KNN	0.3342	0.6608	0.6360
2	SVM	0.3298	0.6969	0.5975
3	RF	0.3253	0.6660	0.6139

모델별 평균 성능을 비교한 결과 <Table 7>, KNN이 평균 F2-score 0.3342로 가장 높았다. KNN은 Recall 0.6608, TNR 0.6360을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 균형 잡힌 결과를 보였다. 다만 KNN의 상대적 우위는 특성 선택을 거쳐 생존 변수 수가 축소된 환경에서 측정된 결과로, 고차원 원본 데이터에서의 일반적인 KNN 한계와는 상이한 조건임을 고

려할 필요가 있다. 또한 KNN은 생존 파이프라인 수가 상대적으로 적어, 특정 전처리 조합에서만 높은 성능을 보이는 경향이 있었는데, 이는 특정 전처리 및 특성 선택 조합에서 유사도 기반 분류 방식이 SECOM 데이터의 일부 구조를 효과적으로 반영했을 가능성을 보여준다. SVM은 평균 F2-score 0.3298로 두 번째에 위치하였으며, Recall은 0.6969으로 상위 3개 모델 중 가장 높게 나타났다. 이는 SVM이 불량 샘플을 탐지하는 데 상대적으로 민감하게 작동했음을 의미한다. 다만 TNR은 0.5975으로 KNN 및 RF보다 낮아, 정상 샘플 오분류 가능성은 상대적으로 큰 것으로 해석된다. RF는 평균 F2-score 0.3253으로 세 번째에 위치하였다. 그러나 RF는 생존 파이프라인 수가 39개로 가장 많았다. 이는 RF가 특정 소수 조합에서만 우수한 것이 아니라, 다양한 대치·균형화·특성 선택 조건에서 안정적으로 필터 조건을 만족했음을 의미한다. 따라서 평균 F2-score 기준으로는 KNN과 SVM이 더 높게 나타났지만, 실험 전반의 안정성 측면에서는 RF 역시 중요한 후보 모델로 판단된다.

종합적으로 모델 비교 결과, 평균 F2-score 기준으로는 KNN과 SVM이 높았으나, 실험 전반의 안정성 측면에서는 RF가 다양한 조건에서 안정적으로 작동하는 모델로 확인되었다.

4.6 결측지시변수 추가 효과 분석

상위 성능 조합들을 분석한 결과, 가장 높은 성능을 기록한 조합은 MICE / Raw / mutual_info / RF 조합으로 확인되었다. 이는 결측지시변수의 추가가 모든 환경에서 항상 최고 성능으로 이어지는 것은 아님을 보여준다. 반면 생존 파이프라인 중 두 번째로 높은 성능을 기록한 mean_M / SMOTE / fpr / HGB 조합은 결측지시변수의 효과가 비교적 뚜렷하게 관찰된 대표 사례였다. 해당 조합은 동일 조건에서 결측지시변수를 사용하지 않은 mean / SMOTE / fpr / HGB 조합과 비교하여 Recall을 유지하면서 F2-score와 TNR이 동시에 향상되었다.

<Table 8> Representative Pipeline Showing the effect of M Feature

Pipeline	F2	Recall	TNR
Mean/SMOTE/FPR/HGB	0.3618	0.6494	0.7005
Mean_M/SMOTE/FPR/HGB	0.3695	0.6494	0.7157

mean_M / SMOTE / fpr / HGB 조합은 결측지시변수 추가 이후 Recall 성능 변화 없이 TNR과 F2-score가 향상된 대표적인 사례로 확인되었다 <Table 8>. 특히 Recall이 유지된 상태에서 TNR이 증가하였다는 점은, 결측지시변수가 단순히 불량 예측을 공격적으로 증가시키는 것이 아니라 정상 샘플 구분에도 보조적인 정보를 제공했음을 시사한다. 즉 결측지시변수는 독립적으로 강한 예측 변수라기보다 특정 전처리·모델 조합 환경에서 보조 신호로 작동할 가능성이 있는 것으로 해석된다. 또한 생존한 조합 중 결측지시변수 추가 이후 F2-score가 상승한 조합은 총 36개로 확인되었으며, Mean_M / Raw / FPR / RF, InpaintingKNN_M / Raw / mutual_info / RF 조합에서도 비교적 뚜렷한 성능 향상이 관찰되었으며, Missforest_M / SMOTE / Raw / RF 조합의 경우 Recall 0.8586을 기록하여 불량 검출 측면에서 높은 성능을 보였다.

종합적으로 결측지시변수는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 조합에서는 불량 검출 성능과 정상 샘플 구분 성능을 동시에 개선하는 효과를 보였다. 해당 결과는 결측 여부 정보가 단순히 제거되어야 하는 노이즈가 아니라 특정 환경에서는 공정 이상과 관련된 보조적 정보로 활용될 가능성이 있음을 시사한다.

4.7 최종 추천 파이프라인 조합

앞서 정의한 생존 파이프라인 조합 중 F2-score 기준 상위 3개의 파이프라인 조합을 최종 추천 조합으로 선정하였다. 앞선 4.2 ~ 4.5절의 구성 요소별 평균 비교와 달리, 개별 파이프라인 단위의 절대 성능 기준으로 최종 추천 조합을 선정하였다.

<Table 9> Final Recommended Pipeline Combinations


Pipeline	F2	Recall	TNR
MICE/Raw/mutual_info/RF	0.3885	0.6707	0.7278
Mean_M/SMOTE/FPR/HGB	0.3695	0.6494	0.7157
MICE/SMOTE/FPR/RF	0.3659	0.6949	0.6740

최종 추천 파이프라인 조합들은 생존 파이프라인 중 F2-score 기준 상위권 성능을 기록한 조합들로 구성되었다. MICE / Raw / Mutual Information / RF 조합은 전체 조합 중 가장 높은 F2-score를 기록하여 전반적인 불량 검출 성능 측면에서 가장 우수한 결과를 보였다. 반면 Mean_M / SMOTE / FPR / HGB 조합은 결측지시변수 추가 효과가 비교적 뚜렷하게 관찰된 대표 사례였다. 해당 조합은 결측지시변수를 사용하지 않은 동일 조건의 조합과 비교하여 Recall 성능 저하 없이 TNR과 F2-score가 동시에 향상되었다는 점에서 의미가 있었다. 또한 MICE / SMOTE / FPR / RF 조합은 세 조합 중 가장 높은 Recall 성능을 기록하였다. 해당 조합은 불량 샘플 검출 측면에서 비교적 우수한 성능을 보였다.

4.8 M_only 기반 결측 패턴 효과 분석


원본 특성을 제외하고 결측지시변수만 사용하였을 때의 불량 검출 성능을 분석하여, 결측 발생 패턴 자체가 공정 이상과 관련된 정보를 포함하고 있는지 확인하고자 하였다. 전체 137개의 생존 파이프라인 조합 중 결측지시변수만 사용한 조합은 총 15개로 확인되었다. 이는 전체 생존 조합의 약 10.95%에 해당한다. 또한 결측지시변수만 사용한 조합 중 최고 성능을 기록한 조합은 전체 파이프라인 순위 기준 약 상위 50.5% 수준에 해당하였다. 이는 원본 특성 없이 결측 여부 정보만 사용하였음에도 일부 조합에서 일정 수준 이상의 불량 검출 성능이 가능했음을 의미한다. 결측지시변수만 사용한 생존 파이프라인 조합 15개를 분석한 결과, 모든 조합에서 균형화 기법을 적용하지 않은 Raw 조건만 관찰되었다. 이는 결측 패턴만으로도 합성 오버샘플링을 적용하지 않은 상태에서 Recall과 TNR 기준을 만족하는 조합이 존재했음을 보여준다. 특성 선택 측면에선 χ^2 , f_classif, FPR이 각각 5회씩 동일하게 등장하였다. 즉 특정 특성 선택 기

법이 압도적으로 우세하게 나타나지는 않았으며, 여러 단일변수 기반 선택 기법에서 유사한 수준의 생존 조합이 확인되었다.



<Figure 3> Feature Selection Distribution in Surviving M_only Pipelines


모델 측면에서도 XGBoost, 로지스틱 회귀, KNN, HGB, RF가 각각 3회씩 동일하게 등장하였다. 결측지시변수만 사용한 생존 파이프라인은 특정 모델 하나에 집중되지 않고 다양한 모델 환경에서 비교적 고르게 관찰되었음을 확인할 수 있다.



<Figure 4> Model Distribution in Surviving M_only Pipelines

또한 성능 역시 특정 조합에서만 급격히 높아지기보다 비교적 안정적인 수준으로 분포하였다. 실제로 결측지시변수만 사용한 생존 파이프라인의 F2-score는 평균 0.2736 수준으로 나타났으며, 최대값과 최소값 역시 각각 0.2752과 0.2703로 큰 차이를 보이지 않았다.

종합적으로 결측지시변수만 사용한 조합은 전체 최고 성능 수준에는 도달하지 못하였으나, 원본 특성 없이 결측 여부 정보만 사용하였음에도 일부 조합에서 생존 파이프라인 조건을 만족하였다. 이



<Figure 5> Supplementary Analysis and Key Findings

는 단순 편향 분류기로는 달성할 수 없는 수준으로, 원 공정 변수 없이 결측 여부 정보만으로도 일정 수준의 분류 정보가 내포되어 있음을 시사한다. 또한 생존 조합이 특정 특성 선택 기법이나 특정 모델에 편중되지 않았다는 점에서, 결측 패턴 자체가 고장 검출에 활용 가능한 제한적인 보조 정보를 포함할 가능성을 시사한다. 따라서 결측지시변수만 사용한 경우는 독립적인 핵심 예측 변수로 사용되기에는 한계가 있으나, 기존 공정 변수와 함께 사용될 경우 고장 검출 성능을 보조하는 신호로 활용될 수 있다. 이상의 결측지시변수만 사용한 파이프라인의 분석 결과와 최종 추천 파이프라인의 핵심 결과는 <Figure 5>에 요약하였다.

5. 결 론

결측치와 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 머신러닝 기반 불량 검출 성능을 분석하기 위해 다양한 파이프라인 조합을 비교·평가하였다. 이를 위해 결측치 대체 방법, 클래스 불균형 처리 적용 여부, 특성 선택 기법, 분류 모델을 조합한 총 924개의 파이프라인을 구성하였으며, SECOM 데이터셋을 기반으로 실험을 수행하였다.

실험 결과 파이프라인 구성 요소에 따라 불량 검출 성능 차이가 크게 나타났으며, 특히 MICE 기반 대체, f_classif 및 FPR 기반 특성 선택, 그리고 RF 계열 조합이 비교적 안정적인 성능을 보였다. SMOTE는 Recall 및 F2-score를 일부 향상시키는 경향을 나타냈으나, 그 효과는 다른 전처리 및 모델 조합에 따라 달라지는 것으로 확인되었다. 또한, 결측 여부 자체를 나타내는 결측지시변수를 추가적으로 도입하여 결측 패턴의 정보적 활용 가능

성을 분석하였다. 실험 결과, 결측지시변수는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 조합에서는 Recall 저하 없이 TNR과 F2-score를 동시에 향상시키는 결과가 관찰되었다. 또한 결측지시변수만 사용한 조합에서도 제한적이거나 일정 수준 이상의 불량 검출 성능이 확인되었다. 이는 결측 정보가 단순한 노이즈가 아니라 특정 환경에서는 공정 이상과 관련된 보조적 신호로 활용될 수 있음을 시사한다.

이 연구는 반도체 공정의 결측 및 불균형 환경에서 머신러닝 파이프라인 구성 요소들의 성능 특성을 체계적으로 비교·분석하고, 결측 패턴 자체의 활용 가능성을 실험적으로 검증함으로써 산업 공정 데이터 기반 불량 검출 연구에서 결측 정보 활용에 대한 기초적 방향성을 제시하였다는 점에서 의의를 가진다. 향후 연구에서는 실제 공정 환경에 보다 근접한 데이터셋을 활용한 외부 검증과 함께, 결측치를 별도로 대체하지 않고 결측 구조 자체를 모델이 직접 학습하는 접근으로의 확장을 고려할 수 있다. 최근 마스킹 기반 자기지도 학습 [3]이나 어텐션 기반의 비대치(no-imputation) 학습 기법 [1][16]은 결측을 복원 대상이 아닌 정보원으로 다루며, 확산 모델 기반 결측치 대체 기법 [20]은 결측 구조를 생성 모델링을 통해 학습한다는 점에서, 이 연구가 제시한 결측 지시변수의 활용 가능성과 직접적으로 맞닿아 있다. 이러한 방향은 결측 패턴이 내포한 공정 이상 신호를 보다 정교하게 포착하는 후속 연구로 이어질 수 있다.

References

[1] Chang et al.(2025), MFAN Learning on

- Missing Tabular Data: Attention with Self-Supervision, Not Imputation, is All You Need, *ACM Transactions on Intelligent Systems and Technology*, 16(3), Article 73
- [2] Chawla, N.V., Bowyer, K.W., Hall, L.O. and Kegelmeyer, W.P.(2002), SMOTE: Synthetic Minority Over-sampling Technique, *Journal of Artificial Intelligence Research*, Vol.16, pp.321 - 357.
- [3] Du et al.(2024), ReMasker: Imputing Tabular Data with Masked Autoencoding, *arXiv*: 2309.13793,
- [4] Ehrig et al. (2025), Imputation and Missing Indicators for Handling Missing Longitudinal Data: Data Simulation Analysis Based on Electronic Health Record Data, *JMIR Medical Informatics*
- [5] Farrag et al.(2024), Rare Class Prediction Model for Smart Industry in Semiconductor Manufacturing, *arXiv preprint*, *arXiv*:2406.04533,
- [6] Le Morvan et al.(2025), Imputation for prediction: beware of diminishing returns, *arXiv*: 2407.19804,
- [7] Lee et al.(2019), A data-driven approach to selection of critical process steps in the semiconductor manufacturing process considering missing and imbalanced data, *Journal of Manufacturing Systems*, Vol. 52, Part A, pp. 146 - 156
- [8] McCann, M. and Johnston, A.(2008), SECOM Dataset: Data from a Semiconductor Manufacturing Process, *UCI Machine Learning Repository*
- [9] Park et al.(2024), Study on Data Preprocessing for Machine Learning Based on Semiconductor Manufacturing Processes, *Sensors*, 24(17), 5461
- [10] Paterakis et al.(2024), Do We Really Need Imputation in AutoML Predictive Modeling?, *ACM Transactions on Knowledge Discovery from Data*, 18(6)
- [11] Pereira et al.(2024), Imputation of Data Missing Not at Random: Artificial Generation and Benchmark Analysis, *Expert Systems with Applications*, Vol. 249, Article 123654
- [12] Provost, F.(2000), Machine Learning from Imbalanced Data Sets 101, *AAAI Workshop Papers 2000*, Technical Report WS-00-05, pp. 1- 3.
- [13] Rubin, D.B.(1976), Inference and Missing Data, *Biometrika*, Vol.63, No.3, pp.581 - 592.
- [14] Saar-Tsechansky M. and Provost F.(2007), Handling Missing Values When Applying Classification Models, *Journal of Machine Learning Research*, Vol. 8, pp. 1625 - 1657.
- [15] Salem, M., Taheri, S. and Yuan, J.S.(2018), An Experimental Evaluation of Fault Diagnosis from Imbalanced and Incomplete Data for Smart Semiconductor Manufacturing, *Big Data and Cognitive Computing*, Vol.2, No.4, Article 30.
- [16] Samad et al.(2025), No Imputation of Missing Values in Tabular Data Classification Using Incremental Learning, *arXiv preprint*, *arXiv*:2504.14610
- [17] Sperrin, M., Martin, G.P., Sisk, R. and Peek, N.(2020), Missing Data Should Be Handled Differently for Prediction Than for Description or Causal Explanation, *Journal of Clinical Epidemiology*, Vol. 125, pp. 183 - 187.
- [18] Susto, G.A., Schirru, A., Pampuri, S., McLoone, S. and Beghi, A.(2015), Machine Learning for Predictive Maintenance: A Multiple Classifier Approach, *IEEE Transactions on Industrial Informatics*, Vol.11, No.3, pp.812 - 820.
- [19] Van Ness, M., Bosschietter, T.M., Halpin-Gregorio, R. and Udell, M.(2022), The Missing Indicator Method: From Low to High Dimensions, *arXiv preprint arXiv*:2211.09259
- [20] Zhang et al.(2025), DiffPutter: Empowering Diffusion Models for Missing Data Imputation, *ICLR 2025 Spotlight*, OpenReview