

Machine Learning Pipeline Analysis for Improving Semiconductor Defect Detection Performance in Missing Value and Class Imbalanced Environments

NamHo Lee[†], MyungGeun Ji, HwanIl Yu, AhHyun Choi
Department of Industrial Engineering, Konkuk University

결측치 및 클래스 불균형 환경에서의 반도체 불량 검출 성능 향상을 위한 머신러닝 파이프라인 분석

이남호[†], 지명근, 유환일, 최아현
건국대학교 산업공학과

Semiconductor manufacturing data contain missing values and severe class imbalance, making fault detection challenging. Model performance can vary substantially depending on the choice of imputation, class balancing, feature selection, and classification methods. This study systematically analyzes the performance characteristics of machine learning pipeline components under missing and imbalanced data environments and investigates the potential of missingness patterns as auxiliary information through Missing Indicators (M features). A total of 924 pipeline combinations were designed based on the UCI SECOM dataset and evaluated under a 9-fold cross-validation framework with preprocessing procedures conducted within each fold to reduce data leakage. F2-score, Recall, and True Negative Rate (TNR) were adopted as the primary evaluation metrics. The results showed that Random Forest-based pipelines with appropriate imputation and feature selection achieved competitive performance. Furthermore, in several pipeline configurations, the inclusion of Missing Indicators improved TNR and F2-score without degrading Recall, suggesting that missingness patterns can provide useful auxiliary information for fault detection under certain conditions.(차후 결과값 수정에 따라 나중에 작성)

Keywords: Semiconductor Fault Detection, Imbalanced Data, Missing Data, Machine Learning Pipeline, Missing Indicator, SECOM Dataset

1. 서 론

반도체 제조 산업은 초미세 공정과 고집적화 기

술의 발전과 함께 공정 복잡도가 지속적으로 증가하고 있다. 현대 반도체 생산 라인은 수백 단계 이상의 공정으로 구성되며, 각 단계에서는 온도, 압

력, 유량, 전류와 같은 다양한 공정 변수들이 대규모 센서 네트워크를 통해 실시간으로 수집된다. 이러한 공정 데이터는 생산 수율 향상과 품질 안정화를 위한 핵심 자산으로 활용되며, 최근에는 머신러닝 기반 불량 검출 기술에 대한 관심이 크게 증가하고 있다. 특히 공정 이상을 조기에 탐지하여 불량 발생을 최소화하는 것은 생산 수율과 제조 비용에 직접적인 영향을 미치는 핵심 과제로 인식되고 있다.

그러나 실제 반도체 공정 데이터는 높은 차원성, 광범위한 결측치, 그리고 심각한 클래스 불균형 문제를 동시에 포함한다. 대표적인 공개 산업 데이터셋인 SECOM 데이터셋은 수백 개 이상의 센서 변수와 함께 다수의 결측값을 포함하고 있으며, 실제 불량 샘플 비율 또한 전체의 약 6% 수준에 불과하다. 이러한 특성은 일반적인 머신러닝 모델의 학습을 어렵게 만들며, 특히 다수 클래스에 편향된 예측으로 인해 실제로 중요한 불량 샘플 탐지 성능이 저하되는 문제를 초래한다.

이러한 문제를 해결하기 위해 결측치 대체(imputation), 클래스 불균형 처리(balancing), 특성 선택, 분류 모델을 조합하는 다양한 파이프라인이 제안되어 왔다. 특히 SECOM 환경에서는 In-painting KNN 기반 대체와 SMOTE 기반 클래스 불균형 처리를 결합하고, 데이터 누출을 방지하는 파이프라인 기반 검증 구조를 적용했을 때 불량 검출(fault detection) 성능이 향상됨이 보고되었다 [15]. 그러나 기존 연구는 결측값의 제거 또는 추정 기반 복원에 초점을 두어, 결측 발생 패턴 자체가 내포하는 정보적 의미는 상대적으로 제한적으로 다루어져 왔다.

실제 반도체 공정 환경에서 센서 결측은 단순한 무작위 오류라기보다 설비 이상, 공정 불안정, 측정 실패 등과 연관되어 발생할 가능성이 존재한다. 즉 결측 발생 자체가 공정 이상 상태와 관련된 정보를 포함할 가능성이 있으며, 이러한 정보는 불량 검출 과정에서 보조적인 역할을 수행할 수 있다. 이에 결측 여부를 이진 변수 형태로 표현한 결측 지시변수(Missing Indicator, M_{ij})를 도입하고, 기존 공정 변수와 결합하거나 독립적으로 활용하였을 때 불량 검출 성능에 어떠한 영향을 미치는지를 분석하고자 하였다.

특정 단일 모델의 성능 최적화보다, 결측 및 클래스 불균형 환경에서 머신러닝 파이프라인 구성 요

소별 성능 특성 분석에 중점을 두었다. 이를 위해 결측치 대체 방법, 클래스 불균형 처리 여부, 특성 선택 기법, 분류 모델을 조합한 총 924개의 파이프라인을 구성하였으며, 모든 실험은 데이터 누출을 방지하기 위해 K-Fold 기반 파이프라인 내부에서 수행하였다. 또한 F2-score, Recall, TNR(True Negative Rate)을 중심으로 불량 검출 성능을 평가함으로써, 불량 탐지 성능과 정상 샘플 구분 성능 간의 균형을 함께 고려하였다.

주요 기여는 다음과 같다. 첫째, 결측 및 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 다양한 머신러닝 파이프라인 조합을 체계적으로 비교·분석하였다. 둘째, 결측 여부 자체를 나타내는 결측지시변수를 도입하여 결측 패턴의 정보적 활용 가능성을 실험적으로 분석하였다. 셋째, 단순 최고 성능 조합뿐 아니라 생존 파이프라인(surviving pipeline) 기반 분석을 통해 각 파이프라인 구성 요소의 일반적인 성능 경향과 안정성을 함께 분석하였다.

논문의 구성은 다음과 같다. 2장에서는 관련 이론 및 선행 연구를 고찰하고, 3장에서는 실험 파이프라인과 데이터 처리 과정을 설명한다. 4장에서는 실험 결과와 성능 분석을 제시하며, 마지막으로 5장에서는 결론 및 향후 연구 방향을 논의한다.

2. 선행 연구

반도체 제조 공정의 이상 감지는 고차원·불균형 공정 데이터를 다루는 기계학습 문제로 발전해 왔다. 이러한 연구 동향을 공정 이상 감지를 위한 전처리 파이프라인, 결측치 처리 및 결측 지시변수의 활용, 클래스 불균형 대응의 세 가지 관점에서 고찰하고, 기존 연구의 한계와 차별성을 도출한다.

2.1 반도체 공정 데이터의 전처리와 결측 정보 활용

반도체 제조 공정은 수백 단계의 미세 공정으로 구성되며, 각 단계에서 온도, 압력, 유량, 전류 등 다양한 공정 변수가 센서 네트워크를 통해 수집된다. 이러한 고차원 공정 데이터로부터 불량을 조기에 탐지하는 문제는 수율 향상과 품질 안정화에 직접적으로 연결되며, SECOM 데이터셋 [8]의 공

개 이후 반도체 공정 이상 감지 연구에서 주요 벤치마크 문제로 다루어져 왔다. SECOM 데이터셋은 다수의 센서 변수, 결측값, 그리고 약 1:14 수준의 클래스 불균형을 동시에 포함하고 있어 결측 및 불균형 환경에서의 분류 방법론을 검증하는 데 널리 활용되어 왔다. 또한 단일 분류기보다 복수 분류기를 결합하는 접근이 공정 이상 감지에 효과적일 수 있음이 보고되었다 [18].

결측과 불균형이 공존하는 데이터에서는 분류기 선택뿐 아니라 전처리 파이프라인의 설계가 모델 성능에 큰 영향을 미친다. 특히 데이터 정제, 결측치 대체, 클래스 불균형 처리, 특성 선택, 분류로 이어지는 다단계 파이프라인에서는 훈련·검증 분할 이후 각 전처리 과정을 수행해야 데이터 누출을 방지할 수 있다는 점이 강조되어 왔다 [9][15]. 이러한 관점에서 기댓값 최대화(EM) 기반 대체와 오버샘플링의 결합 [7], ADASYN 오버샘플링과 MaxAbs 스케일링을 SVM과 결합하는 접근 [9] 등 다양한 전처리 전략이 탐색되었으며, 결측 및 불균형 환경에서 이상 감지 성능 개선 가능성이 보고되었다.

전처리의 핵심 요소 중 하나인 결측치 처리는 단순히 불완전한 값을 복원하는 문제를 넘어, 결측 발생 자체가 예측에 활용될 수 있는지에 대한 쟁점을 제기한다. 산업 현장의 센서 결측은 설비 이상, 통신 불량, 측정 실패 등 물리적 요인과 연관될 수 있으므로, 단순 무작위 누락(MCAR)이 아닌 정보성 결측 또는 비무작위 결측(MNAR)의 가능성을 고려할 필요가 있다 [13]. 전통적인 접근은 평균 대체나 KNN 기반 기법 등을 통해 완전한 데이터 행렬을 구성하는 데 초점을 두었지만, 예측 모형의 관점에서는 결측치 처리 전략이 기술 통계나 인과 추론 목적의 결측 처리와 다르게 설계될 수 있다 [17].

결측값 처리 방식은 분류 모델의 예측 성능에 영향을 미치며 [14], 결측 여부를 이진 특성으로 표현하는 결측지시변수는 정보성 결측이 존재하는 조건에서 예측 성능 향상에 기여할 가능성이 있다 [19]. 다만 결측지시변수의 효과가 모든 데이터 환경에서 일관되게 나타나는 것은 아니다. 예를 들어 종단(longitudinal) 데이터 환경에서는 결측지시변수를 추가하더라도 전체 예측 성능이나 대체 정확도에서 큰 차이가 나타나지 않았다는 결과가 보고되었다 [4]. 따라서 결측지시변수는 보편적으로 성

능을 향상시키는 기법이라기보다, 결측 발생 패턴이 목표 변수와 관련된 정보를 포함하는 특정 조건에서 보조적 예측 정보로 활용될 수 있는 방법으로 이해할 필요가 있다.

이러한 선행 연구를 바탕으로 본 연구는 SECOM 데이터셋의 결측 패턴이 반도체 불량 검출 과정에서 보조 정보로 활용될 수 있는지 분석한다. 특히 기존 공정 변수에 결측지시변수를 추가한 조건과 결측지시변수만을 사용한 조건을 함께 비교함으로써, 결측 발생 여부 자체가 불량 검출 성능에 미치는 영향을 파이프라인 구성 요소별로 살펴보고자 한다.

2.2 클래스 불균형 대응 및 앙상블 분류 모델

반도체 공정과 같이 양품 대비 불량률의 비율이 극히 낮은 환경에서는 모델이 다수 클래스인 정상 샘플로 예측을 편향하는 문제가 발생할 수 있다. 이러한 문제를 완화하기 위해서는 단순 정확도 중심의 평가를 지양하고, 데이터 분포와 오류 비용을 고려한 샘플링 전략 및 분류 임계값 설정을 함께 검토할 필요가 있다 [12]. 대표적인 불균형 처리 기법인 SMOTE는 소수 클래스 샘플을 합성하여 클래스 분포를 완화하는 데 활용되어 왔으나 [2], 고차원 노이즈 데이터에 부적절하게 적용될 경우 잡음 샘플을 증폭하거나 과적합을 유발할 가능성이 있다.

이러한 한계를 완화하기 위해 샘플링 기법과 특성 선택, 앙상블 분류기를 결합하는 접근이 제안되어 왔다. 예를 들어 다수의 특성 선택 기법을 결합한 앙상블 투표(Voting)와 SMOTE를 함께 활용하여 핵심 변수를 추출하고, 이를 XGBoost에 적용함으로써 클래스 분리도와 소수 클래스 탐지력(Recall)을 개선한 사례가 보고되었다 [5]. 이는 산업 도메인에서 불량을 정상으로 잘못 판단하는 비용(Type II Error)이 정상 샘플을 불량으로 잘못 판단하는 비용(Type I Error)보다 클 수 있다는 점에서, 불량 탐지 성능을 반영한 평가 지표와 모델 설계가 중요함을 시사한다.

2.3 기존 연구의 한계 및 차별성

상기 고찰한 바와 같이, 선행 연구들은 고차원 반도체 공정 데이터의 특성을 반영하여 결측치 대체,

클래스 불균형 처리, 특성 선택, 분류 알고리즘을 조합하는 파이프라인 연구로 발전해 왔다. 그러나 기존 연구의 상당수는 결측값을 제거하거나 대체하여 완전한 입력 행렬을 구성하는 데 초점을 두었으며, 결측 발생 여부 자체가 예측에 제공할 수 있는 보조 정보의 역할은 상대적으로 제한적으로 다루어져 왔다. 또한 대체 정확도의 향상이 반드시 후속 예측 성능 개선으로 이어지지 않는다는 점 [6]과, AutoML 환경에서는 정교한 대체 기법 없이도 경쟁력 있는 예측 성능이 가능하다는 점 [10]이 보고되면서, 대체 방식의 고도화뿐 아니라 결측 패턴 자체의 정보적 활용 가능성을 함께 검토할 필요가 제기되고 있다.

이에 본 연구는 데이터 누출을 줄이기 위한 교차 검증 기반 파이프라인 구조 [9][15]를 기본 골격으로 삼고, 기존 연구를 다음 세 가지 측면에서 확장한다. 첫째, 평균 대체뿐 아니라 In-painting KNN, MICE, MissForest 등 다양한 결측치 대체 방법을 비교하여 대체 방식에 따른 불량 검출 성능 차이를 분석한다. 둘째, 각 대체 조건에 결측지시변수를 결합한 조건과 결측지시변수만을 사용한 조건을 함께 구성하여, 결측 발생 패턴이 분류 성능에 보조적으로 기여할 수 있는지 검토한다. 셋째, KNN, SVM, Logistic Regression과 같은 기본 분류 모델뿐 아니라 Random Forest, XGBoost, HGB(Histogram-based Gradient Boosting) 등 앙상블 및 부스팅 계열 모델을 함께 비교하여, 전처리 조합과 분류 모델 선택에 따른 성능 경향을 분석한다.

3. 연구방법론

3.1 전체 실험 파이프라인 및 교차 검증 설계

본 연구의 분류 파이프라인은 데이터 정제, 결측치 대체, 클래스 불균형 처리, 특성 선택, 분류 모델 학습의 5단계로 구성된다. 각 단계별 방법론을 조합하여 총 924개($11 \times 2 \times 7 \times 6$)의 파이프라인 조합을 설계하고, 유효한 실험 결과를 대상으로 성능을 비교·분석하였다. 모델 학습 및 평가 과정에서 발생할 수 있는 데이터 누출을 방지하기 위해 K-Fold 교차검증($K=9$) 구조를 채택하였다. 결측치 대체를 위한 통계량 산출, SMOTE 기반 합성 샘플


생성, 특성 선택을 위한 통계량 또는 선택 기준 산출은 각 교차검증 루프 내부에서 훈련 데이터만을 기준으로 수행하였다. 이후 훈련 데이터에서 산출된 기준을 검증 데이터에 동일하게 적용하여 파이프라인의 일반화 성능을 평가하였다. 또한 분류 임계값 및 하이퍼파라미터 설정 과정은 훈련 데이터 내부의 검증 절차를 통해 수행하였으며, 구체적인 설정은 4.1절에서 설명한다.

<Table 1> Processing Methods and Total Number of Combinations for Each Pipeline Stage

Step	List of processing methods	Number of methods
1. Imputation	Raw, Raw+M, Mean, Mean+M, Inpainting KNN, Inpainting KNN+M, MICE, MICE+M, MissForest, MissForest+M, M_only	11
2. Balancing	Raw(Not applied), SMOTE	2
3. Feature selection	chi2, f_classif, mutual_info, FPR, FDR, FWE, Raw(Not applied)	7
4. Classification model	KNN, SVM, Logistic Regression, Random Forest, XGBoost, HGB	6
Total number of combinations	$11 \times 2 \times 7 \times 6$	924

3.2 데이터 정제 및 결측 지시변수 생성

수집된 반도체 공정 원본 데이터에 대해 두 단계의 정제를 수행하여 분석에 적합한 입력 데이터를 구성하였다. 첫째, 결측률이 50% 이상인 특성은 정보 복원의 불확실성이 크고 모델 학습에 불안정성을 유발할 수 있다고 판단하여 제거하였다.



<Figure 1> Overall Experimental Design and Pipeline Framework

둘째, 분산이 0.05 이하인 특성은 변동성이 낮아 분류에 기여할 가능성이 제한적이라고 판단하여 추가로 제거하였다. 이 과정을 거친 데이터를 본 연구의 기준 데이터(Raw)로 정의하였다.

이후 정제된 데이터에 남아 있는 결측 패턴이 불량 검출 과정에서 보조 정보로 활용될 수 있는지 분석하기 위해 결측지시변수를 도입하였다. 임의의 샘플 i 와 센서 변수 j 에 대해 원 변수 x_{ij} 가 결측이면 결측지시변수 $M_{ij} = 1$, 관측값이 존재하면 $M_{ij} = 0$ 으로 정의하였다. 이를 통해 각 센서 변수의 값 자체뿐 아니라 해당 값의 결측 발생 여부를 이진 특성으로 표현하였다. 결측지시변수는 실험 설계에 따라 기존 공정 변수와 결합하거나, 결측지시변수만 독립적으로 사용하는 조건으로 모델에 투입되었다.

<Table 2> Conditions for Applying Missing Indicator Variables (M Feature)

Application conditions	Data configuration
Raw	Use only the original variables on which only missing values have been imputed
Raw + M	Combine the M_Features with the original variable in the column direction
M_only	Use only M_Features as independent input variables without original variables

3.3 결측치 대치 및 클래스 불균형 처리

데이터 내 잔존하는 결측치를 처리하기 위해 단순 대치, 이웃 기반 대치, 반복 모델 기반 대치, 트리 기반 대치 등 4가지 대치 기법을 파이프라인에 적용하였다. 비교의 기준점이 되는 평균 대치 (Mean Imputation)를 비롯하여, 이웃 샘플 간의 유사도 또는 거리를 기반으로 결측치를 추정하는 In-painting KNN, 변수 간의 조건부 분포를 반복적으로 모델링하는 MICE(Multiple Imputation by Chained Equations), Random Forest 기반으로 변수 간의 비선형 관계를 활용할 수 있는 MissForest를 사용하였다. 각 대치 기법은 결측지시변수 적용 여부와 결합되었으며, 대치를 적용하지 않은 Raw 조건, Raw+M 조건, 그리고 원 변수 없이 결측지시변수만 사용하는 M_only 조건을 포함하여 총 11가지 입력 조건으로 구성하였다. 반도체 공정 데이터의 클래스 불균형을 완화하기 위해 오버샘플링 기법인 SMOTE(Synthetic Minority Over-sampling Technique)를 적용하였다. SMOTE는 소수 클래스 샘플을 합성하여 훈련 데이터의 클래스 분포를 보정하는 방법으로, 본 연구에서는 SMOTE 적용 조건과 미적용(Raw) 조건을 비교하였다. 데이터 누출을 방지하기 위해 SMOTE는 각 교차검증 루프에서 훈련 데이터에만 적용하였으며, 검증 데이터에는 적용하지 않았다.

3.4 특성 선택(Feature Selection)

고차원 센서 데이터에서 목표 변수와의 관련성이 낮은 변수를 줄이고 모델 학습 효율을 높이기 위해 단변량 통계 및 유의성 검정에 기반한 6가지 특성 선택 기법을 적용하였다. 먼저 카이제곱 통계량 기반 선택(χ^2 test), 클래스 간 평균 차이를 평가하는 ANOVA F-검정(f_classif), 각 특성과 목표 변수 간의 비선형적 의존성을 평가하는 상호정보량(Mutual Information)을 사용하였다. 이 세 기법은 단변량 점수를 기준으로 상위 특성을 선택하는 방식으로 적용하였으며, 본 연구에서는 상위 50개 특성을 선택하도록 설정하였다.

또한 다중 검정 과정에서 발생할 수 있는 오류를 통제하기 위해 위양성률 통제(FPR), 위발견율 통제(FDR), 가족별 오류율 통제(FWE) 기반 선택 방법을 함께 적용하였다. FPR, FDR, FWE는 유의수준 0.05를 기준으로 적용하였다. 특성 선택을 수행하지 않은 Raw 조건을 포함하여 총 7가지 특성 선택 조건을 비교하였다.

3.5 분류 모델 및 성능 평가

M 피치의 결합 효과를 다양한 모델 환경에서 분석하기 위해 6종의 기계학습 모델을 파이프라인의 최종 분류기로 구성하였다. 거리 기반 모델인 KNN, 선형 모델인 Logistic Regression, 커널 기반 모델인 SVM과 함께, 앙상블 및 부스팅 계열 모델인 Random Forest, XGBoost, HGB(Histogram-based Gradient Boosting)를 평가 대상에 포함하였다. 또한 클래스 불균형 환경에서 소수 클래스 탐지 성능을 보완하기 위해 임계값 이동(Threshold Moving) 전략을 적용하였다. 이때 임계값은 외부 검증 fold를 직접 사용하지 않고, 훈련 데이터 내부의 검증 절차를 통해 F2-score를 기준으로 설정하였다.

파이프라인의 성능은 실제 불량 샘플을 놓치지 않고 탐지하는 능력을 중요하게 고려하여 Recall과 F2-score를 핵심 평가지표로 사용하였다. F2-score는 Precision보다 Recall에 더 큰 가중치를 부여하므로, 불량 미탐지 비용이 큰 반도체 공정 환경에 적합한 지표로 판단하였다. 또한 과도한 오탐(False Alarm)으로 인한 현장 적용성 저하를 함께 고려하기 위해 진음성률(TNR)을 보조 지표

로 사용하였다.

아울러 실효성 있는 파이프라인을 선별하기 위해 Recall $\geq$ 0.6 및 TNR $\geq$ 0.5를 동시에 만족하는 조합을 생존 파이프라인(surviving pipeline)으로 정의하였다. Recall $\geq$ 0.6은 실제 불량 샘플의 60% 이상을 탐지하는 최소 기준으로 설정하였으며, TNR $\geq$ 0.5는 정상 샘플 구분 성능이 무작위 수준 이하로 저하되는 조합을 제외하기 위한 기준으로 설정하였다. 이는 반도체 공정에서 불량 미탐지(Type II Error)의 비용이 크지만, 정상 샘플을 과도하게 불량으로 판단하는 오탐(Type I Error) 역시 현장 적용성을 저하시킬 수 있다는 점을 함께 고려한 것이다.

4. 실험 결과 및 분석

생존 기준을 만족한 파이프라인은 유효 평가된 조합 중 총 54개로 확인되었으며, 이를 기준으로 각 파이프라인 구성 요소별 성능 특성을 분석하였다.

4.1 실험 환경 및 하이퍼파라미터 설정

제안한 파이프라인의 성능을 평가하고 데이터 누출 가능성을 줄이기 위해 모든 실험은 9-Fold 교차검증 구조에서 수행하였다. 각 fold에서 결측치 대체, 클래스 불균형 처리, 특성 선택, 스케일링 및 모델 학습은 훈련 데이터만을 기준으로 수행하였으며, 검증 데이터에는 훈련 데이터에서 산출된 기준을 동일하게 적용하였다. 또한 분류 임계값과 일부 모델 하이퍼파라미터는 외부 검증 fold를 직접 사용하지 않고, 훈련 데이터 내부의 holdout 검증 절차를 통해 F2-score를 기준으로 선택하였다.

결측치 대체 기법 중 평균 대체는 각 훈련 fold의 열별 평균값을 산출하여 훈련 데이터와 검증 데이터에 적용하였다. In-painting KNN, MICE, MissForest는 사전에 fold별 훈련·검증 구조를 유지한 상태에서 생성된 대체 결과를 사용하였으며, 각 대체 결과는 동일한 교차검증 구조 안에서 후속 파이프라인에 투입하였다. 결측치시변수는 원본 fold 데이터의 결측 여부를 기준으로 생성하였으며, 원 변수와 결합하는 조건과 결측치시변수만 사용하는 조건을 별도로 구성하였다.

클래스 불균형 처리를 위해 SMOTE 적용 조건과

미적용 조건을 비교하였다. SMOTE는 각 fold의 훈련 데이터에만 적용하였으며, 검증 데이터에는 적용하지 않았다. 이를 통해 합성 샘플 생성 과정에서 검증 데이터의 정보가 훈련 과정에 유입되지 않도록 하였다.

특성 선택 기법은 총 7가지 조건으로 구성하였다. chi2, f_classif, mutual_info는 단변량 점수를 기준으로 상위 50개 특성을 선택하도록 설정하였다. 단, 전체 특성 수가 50개보다 적은 경우에는 선택 가능한 전체 특성을 사용하였다. FPR, FDR, FWE는 p-value 기반 선택 절차에서 유의수준 $\alpha=0.05$ 를 기준으로 적용하였다. 특성 선택을 수행하지 않는 Raw 조건도 함께 포함하였다. 모든 특성 선택 과정은 각 fold의 훈련 데이터에서만 적합한 뒤, 동일한 선택 기준을 검증 데이터에 적용하였다.

분류 모델로는 KNN, SVM, Logistic Regression, Random Forest, XGBoost, HGB를 사용하였다. 거리 기반 또는 선형 모델인 KNN, SVM, Logistic Regression에는 StandardScaler를 적용하였으며, scaler는 훈련 데이터에서만 적합한 뒤 검증 데이터에 동일하게 적용하였다. 기본 모델 설정을 기준으로 하되, 일부 모델에 대해서는 제한된 후보 집합 내에서 하이퍼파라미터를 탐색하였다. KNN은 이웃 수, 가중 방식, 거리 척도를 후보로 두었고, SVM은 C, gamma, class_weight를 후보로 두었다. Logistic Regression은 C와 class_weight를, Random Forest는 트리 수, 최대 깊이, 최소 leaf 샘플 수, class_weight를 후보로 두었다. HGB는 learning_rate, max_iter, max_leaf_nodes, l2_regularization을 후보로 두었으며, XGBoost는 트리 수, 최대 깊이, learning_rate, subsample, colsample_bytree, scale_pos_weight를 후보로 두었다.

하이퍼파라미터 탐색은 전체 후보를 무제한으로 수행하기보다 모델별 최대 후보 수를 제한하여 수행하였다. 각 후보 조합은 훈련 데이터 내부 holdout 검증에서 F2-score를 기준으로 평가하였으며, 가장 높은 F2-score를 보인 하이퍼파라미터와 임계값을 해당 fold의 최종 학습에 사용하였다. 최종 모델은 선택된 설정을 바탕으로 전체 훈련 fold에서 학습한 뒤, 외부 검증 fold에서 Recall, F2-score, TNR을 평가하였다.

<Table 3> Hyper-parameter Candidate Settings by Classification Model

Model	Hyper-parameter Candidate Settings
KNN	$n_neighbors \in \{3, 5, 7, 11, 15\}$ $weights \in \{\text{uniform, distance}\}$ $metric \in \{\text{euclidean, manhattan}\}$
SVM	$kernel = \text{RBF}$ $C \in \{0.1, 1, 10, 50\}$ $gamma \in \{\text{scale, 0.01, 0.001}\}$ $class_weight \in \{\text{None, balanced}\}$
Logistic Regression	$penalty = \text{l2}$ $C \in \{0.01, 0.1, 1, 10\}$ $class_weight \in \{\text{None, balanced}\}$ $max_iter = 10000$
Random Forest	$n_estimators \in \{300, 500\}$ $max_depth \in \{\text{None, 5, 10, 20}\}$ $min_samples_leaf \in \{1, 3, 5\}$ $class_weight \in \{\text{None, balanced, balanced_subsample}\}$
XGBoost	$n_estimators \in \{200, 500\}$ $max_depth \in \{2, 3, 4\}$ $learning_rate \in \{0.03, 0.05, 0.1\}$ $subsample \in \{0.7, 0.9, 1.0\}$ $colsample_bytree \in \{0.7, 0.9, 1.0\}$ $scale_pos_weight = \text{auto}$
HGB	$learning_rate \in \{0.03, 0.05, 0.1\}$ $max_iter \in \{200, 500\}$ $max_leaf_nodes \in \{15, 31, 63\}$ $l2_regularization \in \{0, 0.1, 1\}$

4.2 결측치 대체 방법별 성능 비교

결측치 대체 방법에 따른 불량 검출 성능 차이를 분석하였다. 해당 분석은 동일한 대체 조건을 공유하는 생존 파이프라인들의 평균 성능을 비교한 것으로, 특정 단일 조합의 최고 성능을 비교하는 후속 분석과는 분석 단위가 다르다. 또한 결측치시변 수만을 사용하는 M_only 조건은 원본 공정 변수를 사용하지 않는 별도 분석 대상이므로 본 절의

대치 방법 비교에서는 제외하였다. 대치를 적용하지 않은 Raw 및 Raw_M 조건 역시 기준 입력 조건에 해당하므로, 실제 대치 방법 간 비교에서는 제외하였다.

대치 조건별 성능을 비교한 결과, 실제 대치 기반 조건 중에서는 InpaintingKNN_M이 평균 F2-score 0.3471로 가장 높은 성능을 보였다. InpaintingKNN_M은 Recall 0.6330, TNR 0.6927을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 균형 잡힌 결과를 나타냈다. 두 번째로 높은 성능을 보인 MICE는 평균 F2-score 0.3363, Recall 0.6091, TNR 0.6945를 기록하였다. 이는 MICE 기반 대치가 일부 모델 및 특성 선택 조합에서 정상 샘플 구분 성능을 비교적 안정적으로 유지했음을 보여준다. 세 번째로 높은 성능을 보인 InpaintingKNN은 평균 F2-score 0.3254, Recall 0.6310, TNR 0.6528을 기록하였다.

<Table 4> Top 3 Imputation Pipelines in Surviving Pipelines (N=Survived)

	imputation	N	F2	Recall	TNR
1	InpaintingKNN_M	6	0.3471	0.6330	0.6927
2	MICE	6	0.3363	0.6091	0.6945
3	InpaintingKNN	9	0.3254	0.6310	0.6528

종합적으로, 대치 방법별 성능은 특정 기법 하나가 모든 조건에서 일관되게 우수하다기보다, 결측지시변수의 결합 여부와 후속 특성 선택 및 분류 모델 조합에 따라 달라지는 경향을 보였다. 특히 InpaintingKNN_M이 상위 성능을 기록한 점은 특정 대치 조건에서 결측지시변수가 보조 정보로 활용될 가능성을 시사한다. 반면 MICE와 InpaintingKNN처럼 결측지시변수를 추가하지 않은 조건도 상위권에 포함되어, 결측지시변수의 효과가 모든 대치 방법에서 보편적으로 나타나는 것은 아님을 확인하였다.

4.3 SMOTE 적용여부에 따른 성능비교

SMOTE 적용 여부에 따른 성능을 비교한 결과 SMOTE를 적용하지 않은 Raw 조건은 평균 F2-score 0.3488, Recall 0.6168, TNR 0.7091을 기록하였다. 반면 SMOTE를 적용한 조건은 평균

F2-score 0.3024, Recall 0.6300, TNR 0.5977을 기록하였다. SMOTE 적용 조건은 생존 파이프라인 수가 44개로 Raw 조건의 10개보다 많았으며, Recall 역시 Raw 조건보다 소폭 높게 나타났다. 이는 소수 클래스 샘플을 합성하는 과정이 불량 샘플 탐지 기준을 만족하는 조합을 늘리는 데 일정 부분 기여했음을 시사한다.

그러나 평균 F2-score와 TNR은 Raw 조건에서 더 높게 나타났다. 특히 TNR은 Raw 조건이 0.7091, SMOTE 조건이 0.5977로 나타나, SMOTE 적용 시 불량 탐지 민감도는 다소 높아질 수 있으나 정상 샘플을 올바르게 구분하는 성능은 낮아질 수 있음을 보여주며, SMOTE가 소수 클래스 탐지에는 도움이 될 수 있지만 고차원 결측 데이터 환경에서는 합성 샘플 생성 과정이 정상 샘플에 대한 오분류를 증가시킬 가능성도 있음을 의미한다.

<Table 5> Performance Comparison According to SMOTE Application in Surviving Pipelines

Balancing	N	F2	Recall	TNR
Raw	10	0.3488	0.6168	0.7091
SMOTE	44	0.3024	0.6300	0.5977

종합적으로 SMOTE는 생존 파이프라인 수와 Recall 측면에서는 긍정적인 효과를 보였으나, F2-score와 TNR 측면에서는 Raw 조건보다 낮은 평균 성능을 보였다. 따라서 본 연구 결과에서 SMOTE는 모든 조합에서 일관된 성능 향상을 제공하는 전략이라기보다, 대치 방법, 특성 선택, 분류 모델 조합에 따라 제한적으로 효과가 나타나는 클래스 불균형 처리 방법으로 해석된다.

4.4 특성 선택 방법별 성능 비교

특성 선택 방법별 성능을 생존 파이프라인 기준으로 비교하였다. 분석 결과 특성 선택을 적용하지 않은 Raw 조건이 평균 F2-score 0.3287로 가장 높은 성능을 보였다. Raw 조건은 Recall 0.6369, TNR 0.6470을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 균형 잡힌 결과를 나타냈다. 이는 모든 변수를 유지하는 방식이

일부 생존 파이프라인에서는 정보 손실을 줄이고 불량 탐지 성능을 유지하는 데 유리하게 작용할 수 있음을 시사한다. 두 번째로 높은 성능을 보인 f_classif는 평균 F2-score 0.3130, Recall 0.6259, TNR 0.6232를 기록하였다. 세 번째로 높은 성능을 보인 FPR 방식은 평균 F2-score 0.3118, Recall 0.6271, TNR 0.6165로 f_classif와 유사한 수준의 성능을 보였다. 이 두 방법은 단변량 통계 또는 p-value 기반 선택 절차를 통해 변수 수를 줄이면서도 생존 기준을 만족하는 조합을 형성했다는 점에서 의미가 있다. 한편 mutual_info는 생존 파이프라인 수가 15개로 가장 많았으나, 평균 F2-score는 0.3048로 Raw, f_classif, FPR보다 낮게 나타났다. chi2와 FWE는 각각 평균 F2-score 0.2917, 0.2808을 기록하여 상대적으로 낮은 성능을 보였다. 특히 FWE는 생존 조합 수가 1개에 불과하므로 결과 해석에 주의가 필요하다.

<Table 6> Top 3 Feature Selection Strategies in Surviving Pipelines

	feature selection	N	F2	Recall	TNR
1	Raw	12	0.3287	0.6369	0.6470
2	f_classif	9	0.3130	0.6259	0.6232
3	FPR	11	0.3118	0.6271	0.6165

종합하면 생존 파이프라인 기준에서는 특성 선택을 수행하지 않은 Raw 조건이 가장 높은 평균 성능을 보였으나, 이는 일부 조합에서 모든 변수를 유지하는 것이 정보 손실을 줄였기 때문으로 해석할 수 있다. 반면 f_classif와 FPR은 변수 수를 줄이면서도 비교적 안정적인 성능을 보였으며, 특성 선택 방법의 효과는 대치 방법 및 분류 모델 조합에 따라 달라지는 것으로 확인되었다.

4.5 모델별 성능 비교

모델별 평균 성능을 생존 파이프라인 기준으로 비교한 결과 Random Forest가 평균 F2-score 0.3275로 가장 높은 성능을 보였다. RF는 Recall 0.6260, TNR 0.6523을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 균형 잡힌 결과를 나타냈다. 또한 RF는 생존 파이프라인 수가 12개로 모델 중 가장 많아, 특정 소수 조합에서

만 우수한 성능을 보인 것이 아니라 다양한 전처리 및 특성 선택 조건에서 생존 기준을 만족한 것으로 해석된다. 두 번째로 높은 성능을 보인 KNN은 평균 F2-score 0.3215, Recall 0.6330, TNR 0.6432를 기록하였다. KNN은 RF보다 Recall이 소폭 높게 나타났으나, F2-score와 TNR은 RF보다 낮았다. 이는 일부 전처리 및 특성 선택 조합에서 거리 기반 분류 방식이 불량 샘플 탐지에 효과적으로 작동할 수 있음을 보여주지만, 고차원 원본 데이터에서의 일반적인 KNN 한계를 고려할 때 전처리 조건과 함께 해석할 필요가 있다. 세 번째로 높은 성능을 보인 XGBoost는 평균 F2-score 0.3200, Recall 0.6292, TNR 0.6360을 기록하였다. XGBoost는 RF 및 KNN과 유사한 수준의 Recall을 보였으나, 평균 F2-score와 TNR은 RF보다 낮게 나타났다. 반면 SVM은 생존 파이프라인 수가 4개로 가장 적고 평균 F2-score도 0.2855로 낮아, 본 실험 조건에서는 상대적으로 제한적인 성능을 보였다.


<Table 7> Top 3 Models in Surviving Pipelines

	model	N	F2	Recall	TNR
1	RF	12	0.3275	0.6260	0.6523
2	KNN	9	0.3215	0.6330	0.6432
3	XGBoost	11	0.3200	0.6292	0.6360

종합적으로 모델 비교 결과, 생존 파이프라인 기준에서는 RF가 평균 F2-score, TNR, 생존 조합 수 측면에서 가장 안정적인 성능을 보였다. KNN과 XGBoost 역시 일부 조합에서 경쟁력 있는 성능을 나타냈으나, 전반적인 균형성과 생존 빈도 측면에서는 RF가 가장 우수한 후보 모델로 확인되었다.

4.6 결측지시변수 추가 효과 분석

결측지시변수(M feature)의 추가 효과를 분석하기 위해, 동일한 균형화 조건, 특성 선택 방법, 분류 모델을 공유하면서 결측지시변수 적용 여부만 다른 조합들을 1:1로 대응시켜 성능 차이를 비교하였다. 분석 결과, 결측지시변수는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 파이프라인에서는 F2-score, Recall, TNR을 동시에 개



<Figure 2> Component-wise Performance Comparison in Surviving Pipelines (Top 3)

선하는 효과가 관찰되었다.

본 절의 비교는 통계적 유의성 검정이 아니라 평균 성능 차이에 기반한 경향 분석으로 해석하였다. 생존 파이프라인 중 가장 높은 성능을 보인 조합은 InpaintingKNN_M / Raw / Raw / RF로, 평균 F2-score 0.3891, Recall 0.6263, TNR 0.7604를 기록하였다. 이는 결측지시변수가 결합된 조건이 전체 상위 조합에 포함될 수 있음을 보여준다. 다만 두 번째로 높은 성능을 보인 InpaintingKNN / SMOTE / Raw / XGBoost 조합은 결측지시변수를 사용하지 않은 조건이었으므로, 결측지시변수의 추가가 모든 환경에서 최고 성능으로 이어지는 것은 아님을 확인할 수 있다. 결측지시변수의 효과가 뚜렷하게 나타난 대표 사례는 InpaintingKNN / Raw / mutual_info / RF 조합과 InpaintingKNN_M / Raw / mutual_info / RF 조합의 비교에서 확인되었다. 결측지시변수를 추가한 이후 F2-score는 0.3182에서 0.3766으로 상승하였고, Recall은 0.5616에서 0.6374로, TNR은 0.7051에서 0.7316으로 함께 향상되었다. 이는 해당 조건에서 결측 발생 여부가 불량 샘플 탐지와 정상 샘플 구분 모두에 보조적인 정보를 제공했을 가능성을 시사한다.

전체 1:1 대응 비교 결과, 결측지시변수 추가 이후 F2-score가 상승한 조합은 147개로 확인되었다. 이 중 F2-score가 상승하면서 Recall이 하락하지 않고 TNR도 함께 증가한 조합은 40개였다. 생존 파이프라인에 포함된 M feature 조합만을 기준으로 보면, 결측지시변수 추가 이후 F2-score가 상승한 조합은 12개였으며, F2-score, Recall, TNR이 모두 개선된 조합은 3개로 나타났다. 이러한 결과는 결

측지시변수의 효과가 전체 조합에서 보편적으로 나타나는 성능 향상이라기보다, 특정 대치 방법, 특성 선택, 분류 모델 조합에서 제한적으로 나타나는 보조 효과에 가깝다는 점을 보여준다.

<Table 8> Representative Pipeline Showing the effect of M Feature

Pipeline	F2	Recall	TNR
InpaintingKNN / Raw / mutual_info / RF	0.3182	0.5616	0.7051
InpaintingKNN_M / Raw / mutual_info / RF	0.3766	0.6374	0.7316

종합적으로 결측지시변수는 독립적으로 강한 예측 변수라기보다, 일부 파이프라인 환경에서 기존 공정 변수와 결합될 때 성능을 보완하는 신호로 작동할 가능성이 있다. 특히 InpaintingKNN_M과 같이 결측지시변수를 결합한 조합이 상위 생존 파이프라인에 포함되었다는 점은, 결측 여부 정보가 단순히 제거되어야 할 노이즈가 아니라 특정 조건에서는 불량 검출에 활용 가능한 보조 정보가 될 수 있음을 시사한다.

4.7 최종 추천 파이프라인 조합

앞서 정의한 생존 파이프라인 조합 중 F2-score 기준 상위 3개의 파이프라인 조합을 최종 추천 조합으로 선정하였다. 앞선 4.2-4.5절의 구성 요소별 평균 비교와 달리, 본 절에서는 개별 파이프라인 단위의 절대 성능을 기준으로 최종 추천 조합을 선정하였다.

최종 추천 파이프라인 조합을 비교한 결과, InpaintingKNN_M / Raw / Raw / RF 조합이 평

균 F2-score 0.3891로 가장 높은 성능을 기록하였다. 해당 조합은 Recall 0.6263, TNR 0.7604를 보여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 가장 균형 잡힌 결과를 나타냈다. 특히 결측지 시변수를 포함한 조건이 최상위 조합으로 나타났다는 점에서, 특정 조건에서는 결측 발생 여부가 보조 정보로 활용될 수 있음을 보여준다. 두 번째로 높은 성능을 보인 조합은 InpaintingKNN / SMOTE / Raw / XGBoost로, F2-score 0.3800, Recall 0.6939, TNR 0.6938을 기록하였다. 세 추천 조합 중 가장 높은 Recall을 보였다는 점에서, 불량 샘플 탐지를 상대적으로 중시하는 상황에서 유용한 후보 조합으로 해석된다. 다만 SMOTE 적용으로 인해 정상 샘플 구분 성능과의 균형을 함께 고려할 필요가 있다. 세 번째 조합은 InpaintingKNN_M / Raw / mutual_info / RF로, F2-score 0.3766, Recall 0.6374, TNR 0.7316을 기록하였다. 이 조합은 결측지시변수 추가 효과가 비교적 뚜렷하게 관찰된 대표 사례로, 동일 조건의 InpaintingKNN / Raw / mutual_info / RF 조합과 비교했을 때 F2-score, Recall, TNR이 모두 향상되었다. 따라서 결측지시변수를 활용한 파이프라인의 실질적 가능성을 보여주는 사례로 볼 수 있다.

<Table 9> Final Recommended Pipeline Combinations

Pipeline	F2	Recall	TNR
InpaintingKNN_M / Raw / Raw / RF	0.3891	0.6263	0.7604
InpaintingKNN / SMOTE / Raw / XGBoost	0.3800	0.6939	0.6938
InpaintingKNN_M / Raw / mutual_info / RF	0.3766	0.6374	0.7316


종합적으로 최종 추천 조합에서는 InpaintingKNN 기반 대치와 RF 또는 XGBoost 계열 분류 모델이 상위권에 포함되었다. 또한 상위 3개 조합 중 2개가 결측지시변수를 포함하고 있어, 결측지시변수가 모든 조건에서 일관된 성능 향상을 제공하지는 않더라도 특정 파이프라인 환경에서는 불량 검출 성능을 보완하는 데 기여할 수 있음을 확인하였다.

4.8 M_only 기반 결측 패턴 효과 분석

원본 공정 변수를 제외하고 결측지시변수만 사용

하였을 때의 불량 검출 성능을 분석하여, 결측 발생 패턴 자체가 분류에 활용 가능한 정보를 포함하는지 확인하고자 하였다. 유효 평가된 조합 중 Recall ≥ 0.6 및 TNR ≥ 0.5 기준을 만족한 생존 파이프라인은 총 54개였으며, 이 중 M_only 조건에 해당하는 조합은 14개로 확인되었다. 이는 전체 생존 조합의 약 25.93%에 해당한다.


M_only 생존 파이프라인을 분석한 결과, 모든 조합에서 SMOTE가 적용된 조건만 관찰되었다. 이는 원본 공정 변수 없이 결측 여부 정보만 사용하는 경우에도, 소수 클래스 보강이 함께 적용되었을 때 일부 조합이 Recall과 TNR 기준을 동시에 만족할 수 있음을 보여준다. 특성 선택 측면에서는 FPR이 5회로 가장 많이 나타났고, chi2와 f_classif가 각각 4회씩 관찰되었으며, 특성 선택을 적용하지 않은 Raw 조건은 1회 나타났다. 모델 측면에서는 HGB가 4회로 가장 많았고, Logistic Regression, Random Forest, SVM이 각각 3회, XGBoost가 1회 관찰되었다.



<Figure 3> Feature Selection Distribution in Surviving M_only Pipelines

성능 분포를 살펴보면, M_only 생존 파이프라인의 평균 F2-score는 0.2740으로 나타났으며, 최대값과 최소값은 각각 0.2765와 0.2621이었다. 평균 Recall은 0.6358로 생존 기준을 충분히 만족하였으나, 평균 TNR은 0.5173으로 기준값인 0.5에 근접한 수준이었다. 이는 결측 여부 정보만으로도 일부 조건에서 불량 샘플 탐지 기준을 만족할 수 있지만, 정상 샘플 구분 성능은 제한적임을 의미한다.

종합적으로 M_only 조건은 전체 최고 성능 수준에는 도달하지 못하였으나, 원본 공정 변수 없이 결측 발생 여부만 사용한 경우에도 일부 조합에서 생존 파이프라인 조건을 만족하였다. 이는 결측 패



<Figure 4> Model Distribution in Surviving M_only Pipelines

턴 자체가 제한적이거나 분류에 활용 가능한 정보를 포함할 가능성을 시사한다. 다만 M_only 조합의 TNR이 기준값에 가까운 수준이고, 모든 생존 조합이 SMOTE 조건에서만 나타났다는 점을 고려할 때, 결측 지시변수만을 독립적인 핵심 예측 변수로 사용하기에는 한계가 있다. 따라서 결측 지시변수는 단독 입력보다는 기존 공정 변수와 결합되었을 때 불량 검출 성능을 보완하는 보조 신호로 활용될 가능성이 더 크다고 해석된다.

5. 결 론

본 연구는 결측치와 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 머신러닝 기반 불량 검출 성능을 분석하기 위해 다양한 파이프라인 조합을 비교·평가하였다. 이를 위해 결측치 대체 방법, 클래스 불균형 처리 적용 여부, 특성 선택 기법, 분류 모델을 조합한 총 924개의 파이프라인을 설계하였으며, SECOM 데이터셋을 기반으로 유효한 실험 결과를 분석하였다.

실험 결과, 파이프라인 구성 요소에 따라 불량 검출 성능 차이가 크게 나타났다. 생존 파이프라인 기준으로는 InpaintingKNN_M, MICE, InpaintingKNN 조건이 대체 방법 비교에서 상위권 성능을 보였으며, 특성 선택 방법에서는 특성 선택을 수행하지 않은 Raw 조건과 f_classif, FPR 기반 선택 방식이 비교적 높은 성능을 기록하였다. 모델별 비교에서는 Random Forest가 평균 F2-score, TNR, 생존 조합 수 측면에서 가장 안정적인 성능을 보였고, KNN과 XGBoost 역시 일부 조합에서 경쟁력 있는 성능을 나타냈다. 클래스 불

균형 처리 측면에서 SMOTE는 생존 파이프라인 수와 Recall 측면에서는 긍정적인 효과를 보였으나, 평균 F2-score와 TNR은 SMOTE를 적용하지 않은 Raw 조건에서 더 높게 나타났다. 이는 SMOTE가 소수 클래스 탐지 민감도를 높이는 데 기여할 수 있지만, 정상 샘플 구분 성능과의 균형 측면에서는 전처리 및 모델 조합에 따라 효과가 제한적으로 나타날 수 있음을 보여준다. 또한 결측 여부 자체를 나타내는 결측지시변수를 도입하여 결측 패턴의 정보적 활용 가능성을 분석하였다. 결측지시변수는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 조합에서는 F2-score, Recall, TNR을 동시에 개선하는 효과가 관찰되었다. 특히 InpaintingKNN_M / Raw / mutual_info / RF 조합은 동일 조건의 M feature 미적용 조합보다 세 지표가 모두 향상되어, 특정 파이프라인 환경에서 결측 발생 여부가 보조 정보로 작동할 가능성을 보여주었다. 한편 M_only 조건에서도 일부 조합이 생존 기준을 만족하였으나, 평균 TNR이 기준값에 가까운 수준이었기 때문에 결측지시변수만을 독립적인 핵심 예측 변수로 사용하기에는 한계가 있었다.

결론적으로 본 연구는 반도체 공정의 결측 및 불균형 환경에서 머신러닝 파이프라인 구성 요소들의 성능 특성을 비교·분석하고, 결측 패턴이 특정 조건에서 불량 검출을 보조하는 정보로 활용될 가능성을 확인하였다는 점에서 의의를 가진다. 향후 연구에서는 실제 공정 환경에 보다 근접한 데이터셋을 활용한 외부 검증과 함께, 결측치를 별도로 대체하지 않고 결측 구조 자체를 모델이 직접 학습하는 접근으로의 확장을 고려할 수 있다. 최근 마스킹 기반 자기지도 학습 [3]이나 어텐션 기반의 비대치(no-imputation) 학습 기법 [1][16]은 결측을 단순한 복원 대상이 아니라 모델이 활용할 수 있는 정보로 다룬다는 점에서, 본 연구가 탐색한 결측지시변수의 활용 가능성과 연결된다. 또한 확산 모델 기반 결측치 대체 기법 [20]은 결측 구조를 생성 모델링 관점에서 학습한다는 점에서, 결측 패턴을 보다 정교하게 반영하는 후속 연구 방향으로 고려될 수 있다.

References

- [1] Chang et al.(2025), MFAN Learning on Missing Tabular Data: Attention with Self-Supervision, Not Imputation, is All You Need, *ACM Transactions on Intelligent Systems and Technology*, 16(3), Article 73
- [2] Chawla, N.V., Bowyer, K.W., Hall, L.O. and Kegelmeyer, W.P.(2002), SMOTE: Synthetic Minority Over-sampling Technique, *Journal of Artificial Intelligence Research*, Vol.16, pp.321 - 357.
- [3] Du et al.(2024), ReMasker: Imputing Tabular Data with Masked Autoencoding, *arXiv*: 2309.13793,
- [4] Ehrig et al. (2025), Imputation and Missing Indicators for Handling Missing Longitudinal Data: Data Simulation Analysis Based on Electronic Health Record Data, *JMIR Medical Informatics*
- [5] Farrag et al.(2024), Rare Class Prediction Model for Smart Industry in Semiconductor Manufacturing, *arXiv preprint*, *arXiv*:2406.04533,
- [6] Le Morvan et al.(2025), Imputation for prediction: beware of diminishing returns, *arXiv*: 2407.19804,
- [7] Lee et al.(2019), A data-driven approach to selection of critical process steps in the semiconductor manufacturing process considering missing and imbalanced data, *Journal of Manufacturing Systems*, Vol. 52, Part A, pp. 146 - 156
- [8] McCann, M. and Johnston, A.(2008), SECOM Dataset: Data from a Semiconductor Manufacturing Process, *UCI Machine Learning Repository*
- [9] Park et al.(2024), Study on Data Preprocessing for Machine Learning Based on Semiconductor Manufacturing Processes, *Sensors*, 24(17), 5461
- [10] Paterakis et al.(2024), Do We Really Need Imputation in AutoML Predictive Modeling?, *ACM Transactions on Knowledge Discovery from Data*, 18(6)
- [11] Pereira et al.(2024), Imputation of Data Missing Not at Random: Artificial Generation and Benchmark Analysis, *Expert Systems with Applications*, Vol. 249, Article 123654
- [12] Provost, F.(2000), Machine Learning from Imbalanced Data Sets 101, *AAAI Workshop Papers 2000*, Technical Report WS-00-05, pp. 1-3.
- [13] Rubin, D.B.(1976), Inference and Missing Data, *Biometrika*, Vol.63, No.3, pp.581 - 592.
- [14] Saar-Tsechansky M. and Provost F.(2007), Handling Missing Values When Applying Classification Models, *Journal of Machine Learning Research*, Vol. 8, pp. 1625 - 1657.
- [15] Salem, M., Taheri, S. and Yuan, J.S.(2018), An Experimental Evaluation of Fault Diagnosis from Imbalanced and Incomplete Data for Smart Semiconductor Manufacturing, *Big Data and Cognitive Computing*, Vol.2, No.4, Article 30.
- [16] Samad et al.(2025), No Imputation of Missing Values in Tabular Data Classification Using Incremental Learning, *arXiv preprint*, *arXiv*:2504.14610
- [17] Sperrin, M., Martin, G.P., Sisk, R. and Peek, N.(2020), Missing Data Should Be Handled Differently for Prediction Than for Description or Causal Explanation, *Journal of Clinical Epidemiology*, Vol. 125, pp. 183 - 187.
- [18] Susto, G.A., Schirru, A., Pampuri, S., McLoone, S. and Beghi, A.(2015), Machine Learning for Predictive Maintenance: A Multiple Classifier Approach, *IEEE Transactions on Industrial Informatics*, Vol.11, No.3, pp.812 - 820.
- [19] Van Ness, M., Bosschieter, T.M., Halpin-Gregorio, R. and Udell, M.(2022), The Missing Indicator Method: From Low to High Dimensions, *arXiv preprint arXiv*:2211.09259
- [20] Zhang et al.(2025), DiffPuter: Empowering Diffusion Models for Missing Data Imputation, *ICLR 2025 Spotlight*, OpenReview