

Machine Learning Pipeline Analysis for Improving Semiconductor Defect Detection Performance in Missing Value and Class Imbalanced Environments

NamHo Lee[†], MyungGeun Ji, HwanIl Yu, AhHyun Choi
Department of Industrial Engineering, Konkuk University

결측치 및 클래스 불균형 환경에서의 반도체 불량 검출 성능 향상을 위한 머신러닝 파이프라인 분석

이남호[†], 지명근, 유환일, 최아현
건국대학교 산업공학과

Semiconductor manufacturing data often contain high-dimensional sensor variables, missing values, and severe class imbalance, making fault detection challenging. This study analyzes the performance of machine learning pipeline components under such conditions and examines whether missingness patterns can serve as auxiliary information through Missing Indicators (M features). Using the UCI SECOM dataset, 924 candidate pipeline combinations were designed by combining imputation methods, class balancing, feature selection, and classification models. Valid combinations were evaluated under a 9-fold cross-validation framework, with preprocessing and model selection procedures conducted within each fold to reduce data leakage. F2-score, Recall, and True Negative Rate (TNR) were used as evaluation metrics. InpaintingKNN-based imputation and Random Forest classifiers achieved relatively strong performance across valid pipeline combinations. Missing Indicators did not consistently improve performance, but improved F2-score, Recall, and TNR in some matched comparisons, suggesting that missingness patterns can provide auxiliary information for fault detection under specific pipeline conditions.

Keywords: Semiconductor Fault Detection, Imbalanced Data, Missing Data, Machine Learning Pipeline, Missing Indicator, SECOM Dataset

1. 서 론

반도체 제조 산업은 초미세 공정과 고집적화 기술의 발전으로 공정 복잡도가 지속적으로 증가하고 있다. 현대 반도체 생산 라인에서는 온도, 압력, 유량, 전류 등 다양한 공정 변수가 대규모 센서 네트워크를 통해 수집되며, 이러한 데이터는 수율 향상과 품질 안정화를 위한 핵심 자산으로 활용된다. 특히 공정 이상을 조기에 탐지하여 불량 발생을

최소화하는 것은 생산 수율과 제조 비용에 직접적인 영향을 미치는 핵심 과제이다. 그러나 실제 반도체 공정 데이터는 높은 차원성, 광범위한 결측치, 심각한 클래스 불균형 문제를 동시에 포함한다. 대표적인 공개 산업 데이터셋인 SECOM 데이터셋은 수백 개의 센서 변수와 다수의 결측값을 포함하며, 불량 샘플 비율도 전체의 약 6% 수준에 불과하다. 이러한 특성은 모델이 다수 클래스에 편향되도록 만들어, 실제로 중요한 불량 샘플 탐지

성능을 저하시킬 수 있다.

이를 해결하기 위해 결측치 대체(imputation), 클래스 불균형 처리(balancing), 특성 선택, 분류 모델을 조합하는 다양한 파이프라인이 제안되어 왔다. 그러나 기존 연구는 결측값의 제거 또는 추정 기반 복원에 초점을 두는 경우가 많았고, 결측 발생 패턴 자체의 정보적 의미는 제한적으로 다루어져 왔다. 실제 반도체 공정 환경에서 센서 결측은 단순한 무작위 오류가 아니라 설비 이상, 공정 불안정, 측정 실패 등과 연관될 가능성이 있다. 즉 결측 발생 자체가 공정 이상 상태와 관련된 정보를 포함할 수 있으며, 이는 불량 검출 과정에서 보조적 역할을 수행할 수 있다. 이에 본 연구에서는 결측 여부를 이진 변수로 표현한 결측지시변수(Missing Indicator, M feature)를 도입하고, 이를 기존 공정 변수와 결합하거나 독립적으로 활용했을 때의 성능 변화를 분석하였다. 또한 본 연구는 결측 및 클래스 불균형 환경에서 파이프라인 구성 요소별 성능 및 특성 분석에 중점을 두었다. 이를 위해 결측치 대체 방법, 클래스 불균형 처리 여부, 특성 선택 기법, 분류 모델을 조합한 총 924개의 후보 파이프라인을 설계하였으며, 유효하게 평가된 조합을 대상으로 성능을 분석하였다. 모든 평가는 9-Fold 구조에서 수행하였고, SMOTE, 특성 선택, 스케일링, 모델 학습 및 임계값 선택 과정에서 검증 fold 정보가 내부로 유입되지 않도록 구성하였다. 성능 평가는 Recall 값과 F2-score, TNR(True-Negative Rate)을 사용하였다.

본 연구의 주요 구성은 다음과 같다. 첫째, 결측 및 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 다양한 머신러닝 파이프라인 조합을 체계적으로 비교·분석하였다. 둘째, 결측지시변수를 도입하여 결측 패턴의 정보적 활용 가능성을 실험적으로 분석하였다. 셋째, 전체 유효 조합 기준의 구성 요소별 평균 성능을 분석하여 대체 방법, 불균형 처리, 특성 선택, 분류 모델 선택에 따른 전반적인 성능 경향을 확인하였다.

2. 선행 연구

2.1 공정 데이터 전처리와 결측 정보 활용

반도체 제조 공정은 수백 단계의 미세 공정으로 구성되며, 각 단계에서 온도, 압력, 유량, 전류 등 다양한 공정 변수가 센서 네트워크를 통해 수집된

다. 이러한 고차원 공정 데이터로부터 불량을 조기에 탐지하는 문제는 수율 향상과 품질 안정화에 직접적으로 연결되며, SECOM 데이터셋 [9]의 공개 이후 주요 벤치마크 문제로 다루어져 왔다. SECOM 데이터셋은 다수의 센서 변수, 결측값, 약 1:14 수준의 클래스 불균형을 동시에 포함하고 있어 결측 및 불균형 환경에서의 분류 방법론 평가에 널리 활용되어 왔다. 또한 복수 분류기를 결합하는 접근이 공정 이상 감지에 효과적일 수 있음을 확인하였다 [17].

결측과 불균형이 공존하는 데이터에서는 분류 모델 선택뿐 아니라 전처리 파이프라인 설계가 성능에 큰 영향을 미친다. 특히 데이터 정제, 결측치 대체, 클래스 불균형 처리, 특성 선택, 분류로 이어지는 다단계 파이프라인에서는 훈련·검증 분할을 기준으로 각 전처리 과정이 독립적으로 적용되어야 데이터 누출을 방지할 수 있다 [10][14]. 이러한 관점에서 EM 기반 대체와 오버샘플링의 결합 [8], ADASYN 오버샘플링과 MaxAbs 스케일링을 SVM과 결합하는 접근 [10] 등이 제안되었다. 결측치 처리는 불완전한 값을 복원하는 문제를 넘어, 결측 발생 자체가 예측 정보로 활용될 수 있는지에 대한 쟁점을 제기한다. 실제 데이터의 결측은 설비 이상, 통신 불량, 측정 실패 등과 연관될 수 있으므로, MCAR이 아닌 정보성 결측 또는 MNAR의 가능성을 고려할 필요가 있다 [20]. 결측치 처리 전략은 단순한 대체 정확도뿐 아니라 후속 예측 성능과 계산 비용을 함께 고려하여 평가될 필요가 있으며, 대체 후 결측 여부를 나타내는 지시변수를 추가하는 방식이 예측 성능에 기여할 수 있음이 보고되었다 [12]. 또한 예측 모형의 관점에서는 결측치 처리 전략이 기술 통계나 인과 추론 목적의 결측 처리와 다르게 설계될 수 있다 [16]. 결측값 처리 방식은 분류 모델의 예측 성능에 영향을 미치며 [13], 결측 여부를 이진 특성으로 표현하는 결측지시변수는 정보성 결측 조건에서 예측 성능 향상에 기여할 가능성이 있다 [18]. 다만 그 효과가 모든 환경에서 일관되게 나타나는 것은 아니며, 종단 데이터에서는 결측지시변수 추가가 전체 예측 성능이나 대체 정확도에 큰 차이를 만들지 않았다는 결과도 보고되었다 [4]. 따라서 결측지시변수는 보편적 성능 향상 기법이라기보다, 결측 패턴이 목표 변수와 관련된 조건에서 활용 가능한 보조 정보로 이해할 필요가 있다.

2.2 클래스 불균형 대응

반도체 공정과 같이 양품 대비 불량 비율이 낮은 환경에서는 분류 모델이 다수 클래스인 정상 샘플로 예측하는 방향으로 편향되는 문제가 발생할 수 있다. 이러한 클래스 불균형 환경에서는 불량 미탐지(Type II error)가 증가할 수 있으므로, 데이터 분포와 오류 비용을 고려한 샘플링 전략 및 평가 지표 설정이 요구된다 [7]. 대표적인 불균형 처리 기법인 SMOTE는 소수 클래스 샘플을 합성하여 클래스 불균형을 완화하는 데 활용되어 왔으나 [2], 고차원 노이즈 데이터에서는 잡음 샘플 증폭이나 과적합을 유발할 가능성이 있다. 이러한 한계를 완화하기 위해 샘플링 기법, 특성 선택, 앙상블 분류기를 결합하는 접근이 제안되어 왔다. 예를 들어 앙상블 투표 기반 특성 선택과 SMOTE를 함께 활용하고 이를 XGBoost에 적용하여 클래스 분리도와 소수 클래스 탐지력(Recall)을 개선한 사례가 보고되었다 [5]. 이는 불량 미탐지의 비용이 클 수 있는 산업 도메인에서, 불량 탐지 성능을 반영한 평가 지표와 모델 설계가 중요함을 시사한다.

2.3 기존 연구의 한계 및 차별성

선행 연구들은 고차원 반도체 공정 데이터의 특성을 반영하여 결측치 대체, 클래스 불균형 처리, 특성 선택, 분류 알고리즘을 조합하는 파이프라인 연구로 발전해 왔다. 그러나 상당수 연구는 결측값을 제거하거나 대체하여 완전 입력 행렬을 구성하는 데 초점을 두었고, 결측 발생 여부 자체가 제공할 수 있는 보조 정보는 제한적으로 다루어졌다. 또한 대체 정확도 향상이 반드시 후속 예측 성능 개선으로 이어지는 않는다는 점 [6]과, AutoML 환경에서는 정교한 대체 없이도 경쟁력 있는 예측 성능이 가능하다는 점 [11]은 결측 패턴 자체의 정보적 활용 가능성을 함께 검토해야 함을 보여준다.

이에 본 연구는 데이터 누출을 방지하기 위한 교차검증 기반 파이프라인 구조 [10][14][16]를 바탕으로 기존 연구를 확장한다. 첫째, Raw 조건과 평균 대체를 포함하여 In-painting KNN, MICE, MissForest 등 다양한 결측치 처리 조건을 비교한다. 둘째, 각 대체 조건에 결측지시변수를 결합한 조건과 결측지시변수만 사용하는 조건을 함께 구성하여 결측 패턴의 보조 정보 가능성을 검토한다. 셋째, KNN, SVM, Logistic Regression, Random Forest, XGBoost, HGB를 비교하여 전처리 조합과 분류 모델 선택에 따른 성능 경향을 분석한다.

3. 연구방법론

3.1 전체 실험 파이프라인 및 교차 검증 설계

분류 파이프라인은 데이터 정제 및 입력 구성, 결측치 처리, 클래스 불균형 처리, 특성 선택, 분류 모델 학습 및 평가의 단계로 구성된다. 각 단계별 방법론을 조합하여 총 924개($11 \times 2 \times 7 \times 6$)의 후보 파이프라인 조합을 설계하였으며, 이 중 유효 평가 조합을 대상으로 성능을 비교, 분석하였다. 결측치 대체 구성은 11개 조건으로 구성하였고, 클래스 불균형 처리 조건 2개, 특성 선택 조건 7개, 분류 모델 6개를 조합하였다.

모델 학습 및 평가 과정에서 발생할 수 있는 데이터 누출을 방지하기 위해 9-Fold 교차검증 구조를 채택하였다. 결측치 처리는 fold별 훈련 데이터와 검증 데이터를 분리한 상태에서 구성된 대체 결과를 사용하였으며, 평균 대체의 경우 훈련 데이터에서 산출한 통계량을 검증 데이터에 동일하게 적용하였다. 결측지시변수는 각 fold의 원본 결측 여부를 기준으로 생성하여 기존 공정 변수와 결합하거나 독립 입력으로 사용하였다.

특성 선택을 위한 통계량 또는 선택 기준 산출, SMOTE 기반 합성 샘플 생성, 스케일링 및 모델 학습은 각 과정에서 훈련 데이터만을 기준으로 수행하였다. 이후 훈련 데이터에서 산출된 기준을 검증 데이터에 적용하여 파이프라인의 일반화 성능을 평가하였다. 또한 분류 임계값 및 하이퍼파라미터 설정 과정은 외부 검증 fold를 직접 사용하지 않고 훈련 데이터 내부 검증 절차를 통해 수행하였으며, 구체적인 설정은 4.1절에서 설명한다.

3.2 데이터 정제 및 결측 지시변수 생성

본 연구에서는 SECOM 원본 데이터에 대해 두 단계의 정제를 수행하였다. 먼저 결측률이 50% 이상인 특성은 정보 복원의 불확실성이 크고, 이후 분산이 0.05 이하인 특성은 변동성이 낮아 분류 기여도가 제한적일 수 있다고 판단하여 제거하였다. 이 과정을 거친 정제 데이터를 기준 데이터(Raw)로 정의하였다.

이후 정제된 데이터에 남아 있는 결측 패턴이 불량 검출 과정에서 보조 정보로 활용될 수 있는지 분석하기 위해 결측지시변수를 결합하였다. 임의의 샘플 i , 센서 변수 j 에 대해 원 변수 x_{ij} 가 결측이면 결측지시변수 $M_{ij} = 1$, 관측값이 존재하면 $M_{ij} = 0$ 으로 정의하여 각 센서 값의 결측 발생 여

부를 이진 특성으로 표현하였다. 결측지시변수는 기존 공정 변수와 결합하거나, 결측지시변수만 독립적으로 사용하는 조건으로 모델에 투입되었다.

3.3 결측치 대체 및 클래스 불균형 처리

잔존 결측치 처리를 위해 평균 대체(Mean Imputation), In-painting KNN, MICE(Multiple Imputation by Chained Equations), MissForest의 4가지 대체 기법을 파이프라인에 적용하여 총 11가지 결측 대체법을 구성하였다. 또한 대체를 적용하지 않은 Raw 조건을 포함하고, 각 대체 조건에 결측지시변수 적용 여부를 결합하였다. 원 변수 없이 결측지시변수만 사용하는 M_only 조건도 추가하여 총 11가지 입력 조건을 구성하였다(Raw, Raw+M, Mean, Mean+M, In-painting KNN, In-painting KNN+M, MICE, MICE+M, MissForest, MissForest+M, M_only). 이후 클래스 불균형 완화를 위해 SMOTE(Synthetic Minority Over-sampling Technique) 적용 조건과 미적용 조건을 비교하였으며, 데이터 누출을 방지하기 위해 SMOTE는 각 교차검증 루프에서 훈련 데이터에만 적용하고 검증 데이터에는 적용하지 않았다.

Table 1. Conditions for Applying Missing Indicator

Application conditions	Data configuration
Raw	Use only the original variables on which only missing values have been imputed
Raw + M	Combine the M_Features with the original variable in the column direction
M_only	Use only M_Features as independent input variables without original variables

3.4 특성 선택(Feature Selection)

고차원 센서 데이터에서 목표 변수와의 관련성이 낮은 변수를 줄이고 모델 학습 효율을 높이기 위해 단변량 통계 및 유의성 검정 기반의 6가지 특성 선택 기법을 적용하였다. 먼저 카이제곱 통계량 기반 선택(χ^2), 클래스 간 평균 차이를 평가하는 ANOVA F-검정(f_classif), 각 특성과 목표 변수 간의 비선형적 의존성을 평가하는 상호정보량(Mutual Information)을 사용하였다. 이 세 기법은 단변량 점수를 기준으로 상위 50개 특성을 선택하도록 설정하였다. 결측지시변수를 결합한 조건에서는 선택된 원 변수에 대응되는 결측지시변수를 함께 포함하였다. 또한 다중 검정 과정에서 발생할 수 있는 오류를 통제하기 위해 위양성률 통제(FPR), 위발견율 통제(FDR), 클래스 별 오류율 통제(FWE) 기반 선택 방법을 적용하였다. FPR, FDR, FWE는 유의수준 0.05를 기준으로 적용하였다. 특성 선택을 수행하지 않은 Raw 조건을 포함하여 총 7가지 특성 선택 조건을 비교하였다.

3.5 분류 모델 및 성능 평가

분류 모델은 다양한 입력 조건과 전처리 조합의 성능을 분석하기 위해 6종의 머신러닝 모델을 구성하였다. 거리 기반 모델 KNN, 선형 모델 Logistic Regression, 커널 기반 비선형 모델 SVM과 함께, 배깅 기반 앙상블 모델 Random Forest와 부스팅 기반 앙상블 모델인 XGBoost, HGB(Histogram-based Gradient Boosting)를 포함하였다. 또한 클래스 불균형 환경에서 소수 클래스 탐지 성능을 보완하기 위해 임계값 이동(Threshold Moving) 전략을 적용하였으며, 이때 임계값은 외부 검증 fold를 직접 사용하지 않고,




Figure 1. Overall Experimental Framework

훈련 데이터 내부의 검증 절차를 통해 F2-score를 기준으로 설정하였다.

파이프라인의 성능은 실제 불량 샘플을 놓치지 않고 탐지하는 능력을 중요하게 고려하여 Recall과 F2-score를 핵심 평가지표로 사용하였다. F2-score는 Precision보다 Recall에 더 큰 가중치를 부여하므로, 불량 미탐지 비용이 큰 반도체 공정 환경에 적합한 지표로 판단하였다. 또한 과도한 오탐(False Alarm)으로 인한 현장 적용성 저하를 함께 고려하여 TNR을 보조 지표로 사용하였다.

4. 실험 결과 및 분석

4.1 실험 환경 및 하이퍼파라미터 설정

제안한 파이프라인의 성능을 평가하고 데이터 누출 가능성을 줄이기 위해 모든 실험은 9-Fold 교차검증 구조에서 수행하였다. 각 fold에서 클래스 불균형 처리, 특성 선택, 스케일링 및 모델 학습은 훈련 데이터만을 기준으로 수행하였으며, 검증 데이터에는 훈련 데이터에서 산출된 기준을 동일하게 적용하였다. 또한 분류 임계값과 일부 모델 하이퍼파라미터는 외부 검증 fold를 직접 사용하지 않고, 훈련 데이터 내부의 holdout 검증 절차를 통해 F2-score를 기준으로 선택하였다.

결측치 대체 기법 중 평균 대체는 각 훈련 fold의 열별 평균값을 산출하여 훈련 데이터와 검증 데이터에 적용하였다. In-painting KNN, MICE, MissForest는 사전에 fold별 훈련·검증 구조를 유지한 상태에서 생성된 대체 결과를 사용하였으며, 각 대체 결과는 동일한 교차검증 구조 안에서 후속 파이프라인에 투입하였다. 결측지시변수는 원본 fold 데이터의 결측 여부를 기준으로 생성하였으며, 원 변수와 결합하는 조건과 결측지시변수만 사용하는 조건을 별도로 구성하였다. 이후 클래스 불균형 처리를 위해 SMOTE 적용 조건과 미적용 조건을 비교하였다. SMOTE는 각 fold의 훈련 데이터에만 적용하였으며, 검증 데이터에는 적용하지 않았다.

특성 선택 기법은 총 7가지 조건으로 구성하였다. χ^2 , f_classif, mutual_info는 단변량 점수를 기준으로 상위 50개 특성을 선택하도록 설정하였다. 단, 전체 특성 수가 50개보다 적은 경우에는 선택 가능한 전체 특성을 사용하였다. FPR, FDR, FWE는 p-value 기반 선택 절차에서 유의수준 0.05를 기준으로 적용하였다. 또한 특성 선택을 수행하지 않는 Raw 조건도 함께 포함하였다. 모든 특성 선

택 과정은 각 fold의 훈련 데이터에서만 적합한 뒤, 동일한 선택 기준을 검증 데이터에 적용하였다. 분류 모델로는 KNN, SVM, Logistic Regression, Random Forest, XGBoost, HGB를 사용하였다. 거리 기반 또는 선형 모델인 KNN, SVM, Logistic Regression에는 StandardScaler를 적용하였으며, scaler는 훈련 데이터에서만 적합한 뒤 검증 데이터에 동일하게 적용하였다. 기본 모델 설정을 기준으로 하되, 일부 모델에 대해서는 제한된 후보 집합 내에서 하이퍼파라미터를 탐색하였다. KNN은 이웃 수, 가중 방식, 거리 척도를 후보로 두었고, SVM은 C, gamma, class_weight를 후보로 두었다. Logistic Regression은 C와 class_weight를, Random Forest는 트리 수, 최대 깊이, 최소 leaf 샘플 수, class_weight를 후보로 두었다. HGB는 learning_rate, max_iter, max_leaf_nodes, l2_regularization을 후보로 두었으며, XGBoost는 트리 수, 최대 깊이, learning_rate, subsample, colsample_bytree, scale_pos_weight를 후보로 두었다. 하이퍼파라미터 탐색은 모델별 최대 후보 수를 제한하여 수행하였다. 각 후보 조합은 훈련데이터 내부 holdout 검증에서 F2-score를 기준으로 평가하였으며, 가장 높은 F2-score를 보인 하이퍼파라미터와 임계값을 해당 fold의 최종 학습에 사용하였다. 최종 모델은 선택된 설정을 바탕으로 전체 훈련 fold에서 학습한 뒤, 외부 검증 fold에서 Recall, F2-score, TNR을 평가하였다.

4.2 결측치 대체 방법별 성능 비교

원본 공정 변수를 사용하지 않는 M_only 조건과 대체를 적용하지 않은 Raw, Raw_M 조건을 제외하고, 실제 대체 기반 입력 조건을 대상으로 전체 유효 파이프라인 조합의 평균 성능을 비교하였다. 따라서 본 분석은 특정 단일 조합의 최고 성능이 아니라, 동일한 대체 조건을 공유하는 조합들의 전반적인 성능 경향을 확인하는 데 목적이 있다.

대체 조건별 평균 성능을 비교한 결과, InpaintingKNN이 평균 F2-score 0.2985로 가장 높은 값을 보였다. InpaintingKNN은 Recall 0.5079, TNR 0.7315를 기록하여 정상 샘플 구분 성능을 비교적 안정적으로 유지하면서도 가장 높은 평균 F2-score를 나타냈다. 다음으로 InpaintingKNN_M은 F2-score 0.2946, Recall 0.5161, TNR 0.7127을 기록하였는데 이는 결측지시변수 결합이 Recall을 소폭 높이는 데 기여할 수 있으나, 전체 평균 기준에서는 TNR이 다소 낮아지면서 F2-score가

InpaintingKNN보다 약간 낮게 나타난 것으로 파악됐다. MICE는 F2-score 0.2935, Recall 0.5018, TNR 0.7276으로 세 번째로 높은 성능을 보였다.

전체 유효 조합 기준에서는 InpaintingKNN 계열이 상대적으로 우수한 평균 성능을 보였으나, 결측지시변수를 결합한 조건이 항상 더 높은 F2-score로 이어지는 않았다. 따라서 결측지시변수의 효과는 대치 방법 자체보다 후속 특성 선택, 클래스 불균형 처리, 분류 모델과의 조합에 따라 달라지는 보조적 효과로 해석하는 것이 적절하다.

Table 2. Hyper-parameter Candidate Settings by Classification Model

Model	Hyper-parameter Candidate Settings
KNN	n_neighbors $\in \{3, 5, 7, 11, 15\}$ weights $\in \{\text{uniform, distance}\}$ metric $\in \{\text{euclidean, manhattan}\}$
SVM	kernel = RBF C $\in \{0.1, 1, 10, 50\}$ gamma $\in \{\text{scale, 0.01, 0.001}\}$ class_weight $\in \{\text{None, balanced}\}$
Logistic Regression	penalty = l2 C $\in \{0.01, 0.1, 1, 10\}$ class_weight $\in \{\text{None, balanced}\}$ max_iter = 10000
Random Forest	n_estimators $\in \{300, 500\}$ max_depth $\in \{\text{None, 5, 10, 20}\}$ min_samples_leaf $\in \{1, 3, 5\}$ class_weight $\in \{\text{None, balanced, balanced_subsample}\}$
XGBoost	n_estimators $\in \{200, 500\}$ max_depth $\in \{2, 3, 4\}$ learning_rate $\in \{0.03, 0.05, 0.1\}$ subsample $\in \{0.7, 0.9, 1.0\}$ colsample_bytree $\in \{0.7, 0.9, 1.0\}$ scale_pos_weight = auto
HGB	learning_rate $\in \{0.03, 0.05, 0.1\}$ max_iter $\in \{200, 500\}$ max_leaf_nodes $\in \{15, 31, 63\}$ l2_regularization $\in \{0, 0.1, 1\}$

Table 3. Top 3 Imputation Pipelines in Surviving Pipelines

	imputation	F2	Recall	TNR
1	InpaintingKNN	0.2985	0.5079	0.7315
2	InpaintingKNN_M	0.2946	0.5161	0.7127
3	MICE	0.2935	0.5018	0.7276

4.3 SMOTE 적용 여부에 따른 성능 비교

SMOTE를 적용하지 않은 Raw 조건은 평균 F2-score 0.2857, Recall 0.5062, TNR 0.7069를 기록하였다. 반면 SMOTE 적용 조건은 평균 F2-score 0.2855, Recall 0.5306, TNR 0.6754로 나타났다. SMOTE 적용 조건은 Recall이 Raw 조건보다 높아 소수 클래스인 불량 샘플 탐지 민감도를 일부 개선하는 경향을 보였다. 그러나 평균 F2-score는 차이가 거의 없었으며, TNR은 SMOTE 적용 조건에서 더 낮게 나타났다. 이는 SMOTE가 불량 샘플 탐지에는 일정 부분 기여할 수 있으나, 합성 샘플 생성 과정에서 정상 샘플에 대한 오분류가 증가할 가능성도 함께 존재함을 시사한다.

Table 4. Performance Comparison According to SMOTE Application in Surviving Pipelines

	Balancing	F2	Recall	TNR
1	Raw	0.2857	0.5062	0.7069
2	SMOTE	0.2855	0.5306	0.6754

SMOTE는 Recall 측면에서는 긍정적인 효과를 보였지만, F2-score와 TNR을 함께 고려했을 때 일관된 성능 향상을 제공하지는 않았다. 따라서 SMOTE는 모든 파이프라인에서 보편적으로 우수한 전략이라기보다, 대치 방법, 특성 선택, 분류 모델 조합에 따라 효과가 달라지는 클래스 불균형 처리 방법으로 해석된다.

4.4 특성 선택 방법별 성능 비교

특성 선택 방법별 분석 결과, FPR 기반 선택이 평균 F2-score 0.3081로 가장 높은 성능을 보였으며, Recall 0.5263, TNR 0.7307을 기록하였다. 두 번째로 높은 성능을 보인 f_classif는 평균 F2-score 0.3044, Recall 0.5169, TNR 0.7339를 기록하였다. f_classif 역시 단변량 통계량을 기준으로 상위 특성을 선택하면서 FPR과 유사한 수준의 성능을 보였다. 특성 선택을 적용하지 않은 Raw 조건은 F2-score 0.2982, Recall 0.5324, TNR 0.7012로 세 번째로 높은 성능을 나타냈다. Raw 조건은 Recall이 상대적으로 높았으나, 전체 평균 기준에서는 FPR 및 f_classif보다 F2-score와 TNR이 낮았다.

Table 5. Top 3 Feature Selection Strategies in Surviving Pipelines

	feature selection	F2	Recall	TNR
1	FPR	0.3081	0.5263	0.7307
2	f_classif	0.3044	0.5169	0.7339
3	Raw	0.2982	0.5324	0.7012

종합하면, 전체 유효 조합 기준에서는 특성 선택을 수행하지 않는 방식보다 FPR 및 f_classif 기반 선택이 평균 F2-score 측면에서 더 우수하게 나타났다. 다만 Raw 조건도 상위권에 포함되어 모든 변수를 유지하는 방식이 일부 조합에서는 정보 손실을 줄이는 데 유리할 수 있음을 확인하였다. 따라서 특성 선택의 효과는 단일 기법의 우열보다는 대치 방법, 클래스 불균형 처리, 분류 모델과의 조합에 따라 달라지는 것으로 해석된다.

4.5 모델별 성능 비교

모델 평균 성능별 분석 결과 Random Forest가 평균 F2-score 0.3048로 가장 높은 성능을 보였으며, Recall 0.5388, TNR 0.7058을 기록하였다. 두 번째로 높은 성능을 보인 XGBoost는 평균 F2-score 0.2889, Recall 0.5269, TNR 0.6887을 기록하였다. XGBoost는 Random Forest보다 낮은 성능을 보였지만, 부스팅 기반 모델로서 전체 조합 평균에서 상위권에 위치하였다. 세 번째로 높은 성능을 보인 HGB는 F2-score 0.2835, Recall 0.5215, TNR 0.6850을 기록하여 XGBoost와 유사한 수준의 경향을 보였다. 반면 KNN은 일부 조건에서는 높은 Recall을 보였으나, 전체 평균 F2-score는 0.2737로 가장 낮게 나타나 전처리 및 특성 선택 조건에 따라 성능 변동이 큰 것으로 해석된다.

Table 6. Top 3 Models in Surviving Pipelines

	model	F2	Recall	TNR
1	Random Forest	0.3048	0.5388	0.7058
2	XGBoost	0.2889	0.5269	0.6887
3	HGB	0.2835	0.5215	0.6850

종합하면, 전체 유효 조합 기준에서는 Random Forest가 평균 F2-score와 TNR 측면에서 가장 안정적인 성능을 보였다. XGBoost와 HGB도 상위권에 포함되었으나 고차원 결측 데이터 환경에서는 트리 기반 앙상블 모델이 상대적으로 유리한 경향을 나타냈다.

4.6 결측지시변수 추가 효과 분석

결측지시변수의 추가 효과를 분석하기 위해, 동일 균형화 조건, 특성 선택 방법, 분류 모델을 공유하면서 결측지시변수 적용 여부만 다른 조합을 1:1로 대응 후 성능 차이를 비교하였다.

분석 결과, 결측지시변수는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 파이프라인에서는 F2-score, Recall, TNR을 동시에 개선하는 효과가 관찰되었다. 전체 유효 조합 중 가장 높은 성능을 보인 조합은 InpaintingKNN_M / Raw / Raw / Random Forest로, 평균 F2-score 0.3891, Recall 0.6263, TNR 0.7604를 기록하였다. 이는 결측지시변수가 결합된 조건이 전체 상위 조합에 포함될 수 있음을 보여준다. 다만 두 번째로 높은 성능을 보인 InpaintingKNN / SMOTE / Raw / XGBoost 조합은 결측지시변수를 사용하지 않은 조건이었으므로, 결측지시변수의 추가가 모든 환경에서 최고 성능으로 이어지는 것은 아님을 확인할 수 있다.

결측지시변수의 효과가 뚜렷하게 나타난 대표 사례는 InpaintingKNN / Raw / mutual_info / Random Forest 조합과 InpaintingKNN_M / Raw / mutual_info / Random Forest 조합의 비교에서 확인되었다. 결측지시변수를 추가한 이후 F2-score는 0.3182에서 0.3766으로 상승하였고, Recall은 0.5616에서 0.6374로, TNR은 0.7051에서 0.7316으로 함께 향상되었다. 이는 해당 조건에서 결측 발생 여부가 모델의 판별 성능 개선에 보조적으로 기여했음을 보여준다.

결측지시변수 추가 이후 F2-score가 상승한 조합은 147개였으며, F2-score, Recall, TNR이 모두 개선된 조합은 40개로 확인되었다. 해당 결과는 결측지시변수의 효과가 전체 조합에서 보편적으로 나타나는 성능 향상이라기보다, 특정 대치 방법, 특성 선택, 분류 모델 조합에서 제한적으로 나타나는 보조 효과에 가깝다는 점을 보여준다.

Table 7. Pipeline Comparison without and with M Feature

	Pipeline	F2	Recall	TNR
1	InpaintingKNN / Raw / mutual_info / Random Forest	0.3182	0.5616	0.7051
2	InpaintingKNN_M / Raw / mutual_info / Random Forest	0.3766	0.6374	0.7316

결측지시변수는 독립적으로 강한 예측 변수라기보다, 일부 파이프라인 환경에서 기존 공정 변수와

결합 시 성능을 보완하는 신호로 작동할 가능성이 있다. 특히 InpaintingKNN_M과 같이 결측지시변수를 결합한 조합이 전체 상위 조합에 포함되었다는 점은 결측 여부 정보가 단순히 제거되어야 할 노이즈가 아니라 특정 조건에서는 불량 검출에 활용 가능한 보조 정보가 될 수 있음으로 보여진다.

4.7 최종 추천 파이프라인 조합

전체 유효 파이프라인 조합 중 평균 F2-score 기준 상위 3개의 조합을 최종 추천 조합으로 선정하였다. 앞선 내용이 구성 요소별 평균 성능을 비교한 것과 달리 개별 파이프라인 단위의 절대 성능을 기준으로 최종 후보를 도출하였다.

InpaintingKNN_M / Raw / Raw / Random Forest 조합이 평균 F2-score 0.3891로 가장 높은 성능을 기록하였다. 해당 조합은 Recall 0.6263, TNR 0.7604를 보여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 가장 균형 잡힌 결과를 나타냈다. 특히 결측지시변수를 포함한 조건이 최상위 조합으로 나타나면서 특정 조건에서는 결측 발생 여부가 보조 정보로 활용될 수 있음을 보여준다. 두 번째 높은 성능을 보인 조합은 InpaintingKNN / SMOTE / Raw / XGBoost로, F2-score 0.3800, Recall 0.6939, TNR 0.6938을 기록하였다. 세 추천 조합 중 가장 높은 Recall을 보였다는 점에서, 불량 샘플 탐지를 상대적으로 중시하는 상황에서 유용한 후보 조합으로 해석된다. 세 번째 조합은 Inpainting-KNN_M / Raw / mutual_info / Random Forest로, F2-score 0.3766, Recall 0.6374, TNR 0.7316을 기록하였다. 이 조합은 결측지시변수 추가 효과가 비교적 뚜렷하게 관찰된 대표 사례로, 동일 조건의 InpaintingKNN / Raw / mutual_info / Random Forest 조합과 비교했을 때 F2-score, Recall, TNR이 모두 향상되었다. 따라서 결측지시변수를 활용한 파이프라인의 실질적 가능성을 보여주는 사례로 볼 수 있다.

Table 8. Final Recommended Pipeline Combinations

	Pipeline	F2	Recall	TNR
1	InpaintingKNN_M / Raw / Raw / Random Forest	0.3891	0.6263	0.7604
2	InpaintingKNN / SMOTE / Raw / XGBoost	0.3800	0.6939	0.6938
3	InpaintingKNN_M / Raw / mutual_info / Random Forest	0.3766	0.6374	0.7316

최종 추천 조합에서는 InpaintingKNN 기반 대치와 Random Forest 또는 XGBoost 계열 분류 모델이 상위권에 포함되었다. 또한 상위 3개 조합 중 2개가 결측지시변수를 포함하고 있어, 결측지시변수가 모든 조건에서 일관된 성능 향상을 제공하지 않더라도 특정 파이프라인 환경에서는 불량 검출 성능을 보완하는 데 기여할 수 있음을 확인하였다.

4.8 결측지시변수 단독 조건 분석

원본 공정 변수를 제외하고 결측지시변수만 사용하였을 때의 불량 검출 성능을 분석하여, 결측 발생 패턴 자체가 분류에 활용 가능한 정보를 포함하는지 확인하였다. 전체 유효 평가 조합 중 M_only 조건은 총 84개였으며, 평균 F2-score 0.2401, Recall 0.6584, TNR 0.4204를 기록하였다. 이는 결측 여부 정보만으로도 불량 샘플 탐지에는 일정 수준 기여할 수 있으나, 정상 샘플 구분 성능은 제한적임을 보여준다.

균형화 조건별로 보면, SMOTE를 적용하지 않은 조건은 F2-score 0.2247, Recall 0.6200, TNR 0.4498을 기록하였다. 반면 SMOTE 적용 조건은 F2-score 0.2554, Recall 0.6969, TNR 0.3909로 나타났다. 즉 SMOTE는 M_only 조건에서 Recall과 F2-score를 높이는 경향을 보였지만, TNR은 오히려 낮아져 정상 샘플 오분류가 증가할 가능성을 함께 보였다. 특성 선택 방법별로는 f_{classif} 와 χ^2 가 각각 F2-score 0.2470, 0.2469로 비교적 높은 성능을 보였으며, 모델별로는 HGB, XGBoost, Logistic Regression, KNN이 유사한 수준의 F2-score를 기록하였다. 다만 일부 조건은 Recall이 높더라도 TNR이 낮게 나타났으므로, 결측 패턴만으로 안정적인 분류 성능에는 한계가 있다.

종합적으로 M_only 조건은 전체 최고 성능 수준에는 도달하지 못했으나, 원본 공정 변수 없이 결측 발생 여부만으로도 불량 탐지에 일정한 신호를 제공할 가능성을 보였다. 다만 평균 TNR이 낮고 SMOTE 적용 시 정상 샘플 구분 성능이 더 저하되는 경향이 확인되었으므로, 결측지시변수는 단독 핵심 예측 변수라기보다 기존 공정 변수와 결합될 때 성능을 보완하는 보조 신호로 해석하는 것이 적절하다.

5. 결 론

본 연구는 결측치와 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 머신러닝 기




Figure 2. Overall M_only Performance




Figure 3. M_only Performance by SMOTE




Figure 4. M_only Performance by Feature Selection Model




Figure 5. M_only Performance by Classification Model

반 불량 검출 성능을 분석하기 위해, 결측치 처리 방법, 클래스 불균형 처리 적용 여부, 특성 선택 기법, 분류 모델을 조합한 총 924개의 후보 파이프라인을 설계하고, SECOM 데이터셋을 기반으로 각 파이프라인의 성능을 비교·평가하였다.

실험 결과, 파이프라인 구성 요소에 따라 불량 검출 성능 차이가 나타났다. 전체 유효 조합 기준에서 대치 방법별 평균 성능은 InpaintingKNN, InpaintingKNN_M, MICE 조건이 상대적으로 높게 나타났으며, 특성 선택 방법에서는 FPR, f_classif, Raw 조건이 상위권을 형성하였다. 모델별 비교에서는 Random Forest가 평균 F2-score와 TNR 측면에서 가장 안정적인 성능을 보였고, XGBoost와 HGB가 그 뒤를 이었다. 클래스 불균형 처리 측면에서 SMOTE는 Recall을 높이는 경향을 보였으나, 평균 F2-score는 SMOTE 미적용 조건과 거의 차이가 없었고 TNR은 낮게 나타났다. 이는 SMOTE가 소수 클래스 탐지 민감도 향상에는 기여할 수 있지만, 정상 샘플 구분 성능과의 균형 측면에서는 조합에 따라 효과가 제한적으로 나타날 수 있음을 보여준다. 또한 결측 여부 자체를 나타내는 결측지시변수를 도입하여 결측 패턴의 정보적 활용 가능성을 분석하였다. 결측지시변수는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 조합에서는 F2-score, Recall, TNR을 동시에 개선하는 효과가 관찰되었다. 특히 InpaintingKNN_M /

Raw / mutual_info / Random Forest 조합은 동일 조건의 결측지시변수 미적용 조합보다 세 지표가 모두 향상되어, 특정 파이프라인 환경에서 결측 발생 여부가 보조 정보로 작동할 가능성을 보여주었다. 한편 M_only 조건은 원본 공정 변수 없이도 Recall 측면에서 일정한 신호를 보였으나, 평균 TNR이 낮게 나타나 결측지시변수만을 독립적인 핵심 예측 변수로 사용하기에는 한계가 있었다.

결론적으로 본 연구는 반도체 공정의 결측 및 불균형 환경에서 머신러닝 파이프라인 구성 요소들의 성능 특성을 비교·분석하고, 결측 패턴이 특정 조건에서 불량 검출을 보조하는 정보로 활용될 가능성을 확인하였다는 점에서 의의를 가진다. 향후 연구에서는 실제 공정 환경에 보다 근접한 데이터셋을 활용한 외부 검증과 함께, 결측치를 별도로 대치하지 않고 결측 구조 자체를 모델이 직접 학습하는 접근으로의 확장을 고려할 수 있다. 최근 마스킹 기반 자기지도 학습 [3]이나 어텐션 기반의 비대치 학습 기법 [1][15]은 결측을 단순한 복원 대상이 아니라 모델이 활용할 수 있는 정보로 다룬다는 점에서 결측지시변수 활용 가능성과 연결된다. 또한 확산 모델 기반 결측치 대치 기법 [19]은 결측 구조를 생성 모델링 관점에서 학습한다는 점에서, 결측 패턴을 보다 정교하게 반영하는 후속 연구 방향으로 고려될 수 있다.

참고문헌

- [1] Chang et al.(2025), MFAN Learning on Missing Tabular Data: Attention with Self-Supervision, Not Imputation, is All You Need, *ACM Transactions on Intelligent Systems and Technology*, 16(3), Article 73.
- [2] Chawla, N.V., Bowyer, K.W., Hall, L.O. and Kegelmeyer, W.P.(2002), SMOTE: Synthetic Minority Over-sampling Technique, *Journal of Artificial Intelligence Research*, Vol.16, pp.321 - 357.
- [3] Du et al.(2024), ReMasker: Imputing Tabular Data with Masked Autoencoding, *arXiv preprint*, arXiv:2309.13793.
- [4] Ehrig et al.(2025), Imputation and Missing Indicators for Handling Missing Longitudinal Data: Data Simulation Analysis Based on Electronic Health Record Data, *JMIR Medical Informatics*.
- [5] Farrag et al.(2024), Rare Class Prediction Model for Smart Industry in Semiconductor Manufacturing, *arXiv preprint*, arXiv:2406.04533.
- [6] Le Morvan et al.(2025), Imputation for prediction: beware of diminishing returns, *arXiv preprint*, arXiv:2407.19804.
- [7] Lee, T., Lee, K.B. and Kim, C.O.(2016), Performance of Machine Learning Algorithms for Class-Imbalanced Process Fault Detection Problems, *IEEE Transactions on Semiconductor Manufacturing*, Vol.29, No.4, pp.436 - 445.
- [8] Lee et al.(2019), A data-driven approach to selection of critical process steps in the semiconductor manufacturing process considering missing and imbalanced data, *Journal of Manufacturing Systems*, Vol.52, Part A, pp.146 - 156.
- [9] McCann, M. and Johnston, A.(2008), SECOM Dataset: Data from a Semiconductor Manufacturing Process, *UCI Machine Learning Repository*.
- [10] Park et al.(2024), Study on Data Preprocessing for Machine Learning Based on Semiconductor Manufacturing Processes, *Sensors*, 24(17), 5461.
- [11] Paterakis et al.(2024), Do We Really Need Imputation in AutoML Predictive Modeling?, *ACM Transactions on Knowledge Discovery from Data*, 18(6).
- [12] Perez-Lebel, A., Varoquaux, G., Le Morvan, M., Josse, J. and Poline, J.-B.(2022), Benchmarking missing-values approaches for predictive models on health databases, *GigaScience*, Vol.11, giac013.
- [13] Saar-Tsechansky, M. and Provost, F.(2007), Handling Missing Values When Applying Classification Models, *Journal of Machine Learning Research*, Vol.8, pp.1625 - 1657.
- [14] Salem, M., Taheri, S. and Yuan, J.S.(2018), An Experimental Evaluation of Fault Diagnosis from Imbalanced and Incomplete Data for Smart Semiconductor Manufacturing, *Big Data and Cognitive Computing*, Vol.2, No.4, Article 30.
- [15] Samad, M.D., Akhter, K.F.B., Rabbani, S.B. and Kowsar, I.(2025), Imputation-free Learning of Tabular Data with Missing Values using Incremental Feature Partitions in Transformer, *arXiv preprint*, arXiv:2504.14610.
- [16] Sperrin, M., Martin, G.P., Sisk, R. and Peek, N.(2020), Missing Data Should Be Handled Differently for Prediction Than for Description or Causal Explanation, *Journal of Clinical Epidemiology*, Vol.125, pp.183 - 187.
- [17] Susto, G.A., Schirru, A., Pampuri, S., McLoone, S. and Beghi, A.(2015), Machine Learning for Predictive Maintenance: A Multiple Classifier Approach, *IEEE Transactions on Industrial Informatics*, Vol.11, No.3, pp.812 - 820.
- [18] Van Ness, M., Bosschieter, T.M., Halpin-Gregorio, R. and Udell, M.(2022), The Missing Indicator Method: From Low to High Dimensions, *arXiv preprint*, arXiv:2211.09259.
- [19] Zhang et al.(2025), DiffPutter: Empowering Diffusion Models for Missing Data Imputation, *ICLR 2025 Spotlight*, OpenReview.
- [20] Zhou, Y., Aryal, S. and Bouadjenek, M.R.(2024), A Comprehensive Review of Handling Missing Data: Exploring Special Missing Mechanisms, *arXiv preprint*, arXiv:2404.04905.