

최종제출

1. 논문

2. Data

3. Code

4. research.

JKIE

가이드라인 확실히 작성.

<06.02 피드백>

3~4월 단어 병행 통일.

장부 쪽수 8~9 p.

→ 6.12 (토) 까지 제출. "통일할 수 있을 정도의 형식 마련"

Performance Analysis of Machine Learning Pipelines for Semiconductor Fault Detection with Missing and Imbalanced Data

NamHo Lee^{*}, MyungGeun Ji, HwanIl Yu, AhHyun Choi

Department of Industrial Engineering, Konkuk University

결측치 및 클래스 불균형 환경에서의 반도체 불량 검출을 위한 머신러닝 파이프라인 ~~성능~~ 분석

성능 향상

이남호^{*}, 지명근, 유환일, 최아현

건국대학교 산업공학과

Semiconductor manufacturing data contain extensive missing values and severe class imbalance, making fault detection challenging. Model performance can vary significantly depending on the choice of imputation, balancing, feature selection, and classification methods. This study systematically analyzes the performance characteristics of machine learning pipeline components under missing and imbalanced environments and investigates the potential of missingness patterns as auxiliary information through Missing Indicators (M features). A total of 924 pipeline combinations based on the UCI SECOM dataset were evaluated using 9-fold cross-validation to prevent data leakage. F2-score, Recall, and True Negative Rate (TNR) were adopted as the primary evaluation metrics. Experimental results showed that the MICE / Raw / Mutual Information / Random Forest pipeline without M features achieved the best performance. Furthermore, in several pipeline configurations, the inclusion of Missing Indicators improved TNR and F2-score without degrading Recall, suggesting that missingness patterns can provide useful auxiliary information for fault detection under certain conditions.

Keywords: Semiconductor Fault Detection, Imbalanced Data, Missing Data, Machine Learning Pipeline, Missing Indicator, SECOM Dataset

1. 서론

반도체 제조 산업은 초미세 공정과 고집적화 기술의 발전과 함께 공정 복잡도가 지속적으로 증가

하고 있다. 현대 반도체 생산 라인은 수백 단계 이상의 공정으로 구성되며, 각 단계에서는 온도, 압력, 유량, 전류와 같은 다양한 공정 변수들이 대규모 센서 네트워크를 통해 실시간으로 수집된다. 이

러한 공정 데이터는 생산 수율 향상과 품질 안정화를 위한 핵심 자산으로 활용되며, 최근에는 머신러닝 기반 fault detection 기술에 대한 관심이 크게 증가하고 있다. 특히 공정 이상을 조기에 탐지하여 불량 발생을 최소화하는 것은 생산 수율과 제조 비용에 직접적인 영향을 미치는 핵심 과제로 인식되고 있다.

그러나 실제 반도체 공정 데이터는 높은 차원성, 광범위한 결측치, 그리고 심각한 클래스 불균형 문제를 동시에 포함한다. 대표적인 공개 산업 데이터셋인 SECOM 데이터셋은 수백 개 이상의 센서 변수와 함께 다수의 결측값을 포함하고 있으며, 실제 불량 샘플 비율 또한 전체의 약 6% 수준에 불과하다. 이러한 특성은 일반적인 머신러닝 모델의 학습을 어렵게 만들며, 특히 다수 클래스에 편향된 예측으로 인해 실제로 중요한 불량 샘플 탐지 성능이 저하되는 문제를 초래한다.

기존 연구들은 이러한 문제를 해결하기 위해 다양한 결측치 대체(imputation), 클래스 불균형 처리(balancing), feature selection, 그리고 분류 모델 조합을 제안해왔다. Salem et al.(2018)은 SECOM 데이터셋 환경에서 결측치 대체와 feature selection, SMOTE 기반 balancing의 조합을 체계적으로 비교하였으며, 데이터 누출을 방지하는 파이프라인 기반 검증 구조의 중요성을 제시하였다. 특히 In-painting KNN 기반 결측치 대체 기법을 제안하여 fault detection 성능 향상을 보고하였다. 그러나 기존 연구들은 주로 결측값 자체의 제거 또는 추정 기반 복원에 초점을 두고 있으며, 결측 발생 패턴 자체가 포함할 수 있는 정보적 의미에 대해서는 상대적으로 제한적으로 다루어져 왔다. 실제 반도체 공정 환경에서 센서 결측은 단순한 무작위 오류라기보다 설비 이상, 공정 불안정, 측정 실패 등과 연관되어 발생할 가능성이 존재한다. 즉 결측 발생 자체가 공정 이상 상태와 관련된 정보를 포함할 가능성이 있으며, 이러한 정보는 fault detection 과정에서 보조적인 역할을 수행할 수 있다. 이에 본 연구는 결측 여부를 이진 변수 형태로 표현한 Missing Indicator(M feature)를 도입하고, 기존 공정 변수와 결합하거나 독립적으로 활용하였을 때 fault detection 성능에 어떠한 영향을 미치는지를 분석하고자 하였다.

본 연구는 특정 단일 모델의 성능 최적화보다, 결측 및 클래스 불균형 환경에서 머신러닝 파이프라인

인 구성 요소별 성능 특성 분석에 중점을 둔다. 이를 위해 결측치 대체 방법, balancing 적용 여부, feature selection 기법, 분류 모델을 조합한 총 924 개의 파이프라인을 구성하였으며, 모든 실험은 데이터 누출을 방지하기 위해 K-Fold 기반 파이프라인 내부에서 수행하였다. 또한 F2-score, Recall, TNR(True Negative Rate)을 중심으로 fault detection 성능을 평가함으로써, 불량 탐지 성능과 정상 샘플 구분 성능 간의 균형을 함께 고려하였다.

본 연구의 주요 기여는 다음과 같다. 첫째, 결측 및 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 다양한 머신러닝 파이프라인 조합을 체계적으로 비교·분석하였다. 둘째, 결측 여부 자체를 나타내는 M feature를 도입하여 결측 패턴의 정보적 활용 가능성을 실험적으로 검증하였다. 셋째, 단순 최고 성능 조합뿐 아니라 surviving pipeline 기반 분석을 통해 각 파이프라인 구성 요소의 일반적인 성능 경향과 안정성을 함께 분석하였다.

본 논문의 구성은 다음과 같다. 2장에서는 관련 이론 및 선행 연구를 고찰하고, 3장에서는 실험 파이프라인과 데이터 처리 과정을 설명한다. 4장에서는 실험 결과와 성능 분석을 제시하며, 마지막으로 5장에서는 결론 및 향후 연구 방향을 논의한다.

2. 선행 연구

본 장에서는 반도체 제조 공정의 이상 감지를 위해 수행된 고차원, 불균형 공정 데이터 기반의 기계학습 연구 동향을 고찰한다. 공정 이상 감지를 위한 전처리 파이프라인 연구, 결측치 처리 및 결측 지시변수의 활용, 그리고 클래스 불균형 문제 해결 방안의 세 가지 관점에서 주요 선행연구를 검토하고, 기존 연구의 한계점과 본 연구의 차별성을 도출한다.

~~2.1 반도체 공정 이상 감지의 전처리 파이프라인~~

불필요 소제거 삭제

반도체 제조 공정은 수백 단계의 미세 공정이 연속적으로 수행되며, 각 단계에서 온도, 압력 등 수천 개의 센서 변수가 실시간으로 수집된다. 이 고차원 공정 데이터로부터 불량을 조기에 탐지하는 것은 수율 향상과 직결된다. McCann et al.(2008)

은 실제 반도체 공정 데이터인 SECOM 데이터셋을 공개하였으며, 해당 데이터셋은 6.7%의 결측치, 약 1:14의 극단적인 클래스 불균형을 동반하여 분류 방법론 검증의 벤치마크로 널리 활용되고 있다. SECOM 데이터를 효과적으로 분류하기 위해 많은 연구가 데이터 전처리 파이프라인의 최적화에 집중해 왔다. Salem et al.(2018)은 데이터 정제, 결측치 대체, 데이터 균형화, 특성 선택, 분류로 이어지는 5단계 파이프라인을 제안하였으며, 특히 훈련 셋과 테스트 셋을 분할한 후에 전처리를 수행하여 데이터 누출(Data Leakage)을 방지하는 교차 검증 설계를 강조하였다.

Lee et al.(2019)은 기댓값 최대화(EM) 알고리즘을 통한 결측치 대체와 SMOTE 기반의 오버샘플링을 결합하여, 다운스트림 분류 성능 자체보다는 물리적인 공정 이상과 직결되는 핵심 공정 단계를 식별하는 데이터 기반 프레임워크를 제안하였다. 최근 Park et al.(2024) 역시 전처리 단계에서 훈련 및 테스트 데이터가 혼합되어 발생하는 정보 누출의 위험성을 지적하며, 엄격한 데이터 분할 후 서포트 벡터 머신(SVM), ADASYN 오버샘플링, MaxAbs 스케일링을 결합했을 때 이상 감지 성능이 극대화됨을 실증하였다.

2.2 결측치 처리 및 결측 지시변수

산업 현장에서 수집된 센서 데이터의 결측은 설비 이상이나 센서 통신 불량 등 물리적 요인과 직결되는 경우가 많아, 단순한 무작위 누락(MCAR)이 아닌 비무작위 결측(MNAR) 메커니즘의 특성을 띠는 경우가 많다. 전통적인 연구들은 평균 대체나 K-최근접 이웃(KNN) 기반의 알고리즘 등 대체(Imputation) 기법을 통해 완전한 데이터 행렬을 복원하는 데 초점을 맞추었다. 그러나 예측 모형 구축의 관점에서는 '결측이 발생했다'는 사실 자체가 잠재적인 상태 정보를 내포할 수 있다. Saar-Tsechansky and Provost(2007)는 결측 발생 여부를 별도의 이진 특성으로 표현하는 결측 지시변수(Missing Indicator) 방식이 특정 조건에서 예측 성능을 크게 향상시킴을 규명하였다.

최근 Van Ness et al.(2022) 등은 고차원 데이터 환경에서 결측 지시변수가 정보성 결측(Informative Missingness) 패턴을 효과적으로 인코딩하여 선형 및 비선형 모델의 강건성과 예측력

을 동시에 높일 수 있음을 이론적·실험적으로 증명하였다.

2.3 클래스 불균형 대응 및 앙상블 분류 모델

반도체 공정과 같이 양품 대비 불량률의 비율이 극히 낮은 환경에서는 모델이 다수 클래스(정상)로 예측을 편향하는 문제가 발생한다. 이를 해결하기 위해 Chawla et al.(2002)이 제안한 SMOTE 기반의 소수 클래스 합성 기법이 표준적으로 활용되어 왔으나, 고차원 노이즈 데이터에 잘못 적용될 경우 오히려 과적합을 유발할 수 있다.

이에 따라 최근 연구들은 샘플링 기법과 함께 강력한 특성 선택 및 앙상블 분류기를 결합하는 방식을 채택하고 있다. Farrag et al.(2024)은 12가지의 서로 다른 특성 선택 기법을 결합한 앙상블 투표(Voting) 방식과 SMOTE를 조합하여 핵심 변수를 추출하고, 이를 XGBoost에 적용하여 클래스 분리도와 소수 클래스 탐지력(Recall)을 획기적으로 개선하였다. 이는 산업 도메인에서 불량을 놓치는 비용(Type II Error)이 오탐 비용(Type I Error)보다 압도적으로 크다는 점을 고려할 때, 정밀도보다 재현율(Recall) 중심의 앙상블 모델링이 중요하며, Recall값을 기반으로 모델의 성능을 확인하는 구체적인 지표로써 활용하였다.

2.4 기존 연구의 한계 및 본 연구의 차별성

상기 고찰한 바와 같이, 선행 연구들은 고차원 반도체 데이터의 특성을 반영하여 결측치 대체, 오버샘플링, 분류 알고리즘을 조합하는 파이프라인 연구로 발전해 왔다. 하지만 대다수의 연구는 결측치 대체 방식의 고도화에만 집중할 뿐, 결측 메커니즘 자체가 가지는 정보량(MNAR)을 결측 지시변수(M Feature) 형태로 분류 모델에 직접 통합하여 그 효과를 체계적으로 규명한 연구는 매우 부족하다.

따라서 본 연구는 Salem et al.(2018)과 Park et al.(2024)이 강조한 데이터 누출 방지 교차검증 구조를 기본 골격으로 채택하되, 기존 연구를 다음 세 가지 측면에서 확장하고자 한다. 첫째, 평균 대체뿐만 아니라 MICE, MissForest 등 다양한 다중 대체 기법으로 범위를 넓힌다. 둘째, 각 대체 조건에 결측 지시변수(Missing Indicator)를 결합하여 결측 패턴 정보의 독립적 기여도를 실증한다. 셋

제, 분류 모델을 XGBoost, HGB(Histogram-based Gradient Boosting) 등 희소 행렬(Sparse Matrix) 처리에 강점이 있는 최신 부스팅 계열로 확장하여, 결측 패턴과 비선형 공정 변수 간의 결합 효과를 통합적으로 분석하고자 한다.

3. 방법론 (약 방법론)

본 장에서는 결측치 및 클래스 불균형 환경에서 반도체 불량 검출 성능을 극대화하기 위해 설계된 머신러닝 파이프라인의 전체 구조와 세부 방법론을 기술한다. ~한다. 시론적 맥락 다룰 색


3.1 전체 실험 파이프라인 및 교차 검증 설계

본질, 본장 이런 이사아구 다 제외
본 연구가 제안하는 분류 파이프라인은 데이터 정제, 결측치 대체(Imputation), 클래스 균형화(Balancing), 특성 선택(Feature Selection), 분류(Classification)의 5단계로 구성된다. 각 단계별로 복수의 방법론을 교차 적용하여 총 924개($11 \times 2 \times 7 \times 6$)의 파이프라인 조합을 생성하고 성능을 비교 분석한다. 모델 학습 과정에서 발생할 수 있는 데이터 누출(Data Leakage)을 원천적으로 방지하기 위해 K-Fold 교차 검증($K=9$) 구조를 채택하였다. 결측치 대체를 위한 통계량 산출, SMOTE 기반의 합성 데이터 생성, 특성 선택을 위한 p-value 산출 등 모든 전처리 과정은 교차 검증 루프 내부에서 훈련 데이터만을 기준으로 수행되며, 산출된 기준을 검증 데이터에 동일하게 적용하여 모델의 일반화 성능을 객관적으로 평가한다. 각 방법론에 대한 구체적인 하이퍼파라미터 셋업 및 튜닝 과정은 4.1

절 실험 환경 및 하이퍼파라미터 설정에서 상세히 다룬다.

<Table 1> Processing Methods and Total Number of Combinations for Each Pipeline Stage

Step	List of processing methods	Number of methods
1. Imputation	raw, raw+M, mean, mean+M, Inpainting KNN, Inpainting KNN+M, MICE, MICE+M, MissForest, MissForest+M, M_only	11
2. Balancing	raw(Not applied), SMOTE	2
3. Feature selection	chi2, f_classif, mutual_info, FPR, FDR, FWE, raw(Not applied)	7
4. Classification model	KNN, SVM, Logistic Regression, Random Forest, XGBoost, HGB	6
Total number of combinations	$11 \times 2 \times 7 \times 6$	924



<Figure 1> Overall Experimental Design and Pipeline Framework

과거 ~ 현재 왔다갔다하는 원본을 고정. (원했다. ~ 하었다 => ~다)
 (?) ~ 평가한다.

3.2 데이터 정제 및 결측 지시변수 생성

수집된 반도체 공정 원본 데이터에 대해 두 단계의 정제를 수행하여 분석의 신뢰성을 확보하였다. 첫째, 50% 이상의 결측률을 가진 특성(Feature)은 유의미한 정보 복원이 불가능하다고 판단하여 제거하였다. 둘째, 분산이 0.05 이하인 특성은 모든 샘플에서 유사한 값을 가져 불량 검출에 기여하지 못하므로 추가로 제거하였다. 이 과정을 거친 데이터를 본 연구의 기준 데이터(Raw)로 정의한다.

이후, 정제된 데이터에 존재하는 결측 패턴 자체가 공정 이상의 유의미한 신호(MNAR: Missing Not At Random)일 수 있다는 가설을 검증하기 위해 결측 지시변수(Missing Indicator, 이하 M 피쳐)를 도입한다. 임의의 센서 변수 x_{ij} 에 대한 M 피쳐 M_{ij} 는 결측 발생 여부에 따라 1(결측) 또는 0(정상 관측)의 이진 값을 갖도록 생성된다. M 피쳐는 실험 설계에 기반하여 세 가지 조건으로 모델에 투입된다.

<Table 2> Conditions for Applying Missing Indicator Variables (M Feature)

Application conditions	Data configuration
Raw	Use only the original variables on which only missing values have been imputed
Raw + M	Combine the M_Features with the original variable in the column direction
M_only	Use only M_Features as independent input variables without original variables

3.3 결측치 대체 및 클래스 불균형 처리

데이터 내 잔존하는 결측치를 처리하기 위해 단순 대체부터 다중 대체에 이르는 4가지 대체 기법을 파이프라인에 적용하였다. 비교의 기준점이 되는 평균 대체(Mean Imputation)를 비롯하여, 결측값의 신뢰도와 이웃 샘플 간의 거리를 기반으로 결측치를 추정하는 In-painting KNN, 변수 간의 조건부 분포를 반복적으로 모델링하는 MICE(Multiple Imputation by Chained Equations), 그리고 비선형적 관계 포착에 강점이 있는 Random Forest 기반의 MissForest를 활용하

였다. 각 대체 기법은 앞서 정의한 M 피쳐 적용 조건과 결합되어 총 11가지의 대체 조건으로 확장된다.

Missmatch
 반도체 공정 데이터의 극단적인 클래스 불균형(양품 대비 불량률의 극소수 분포)을 해소하기 위해 오버샘플링 기법인 SMOTE(Synthetic Minority Over-sampling Technique)를 적용하였다. SMOTE 적용 조건과 미적용(Raw) 조건을 비교하여 데이터 균형화가 불량 검출 성능에 미치는 영향을 평가한다.

3.4 특성 선택 (Feature Selection)

고차원 센서 데이터에 포함된 잡음(Noise) 변수를 제거하고 모델의 학습 효율을 높이기 위해 단변량 통계 및 유의성 검정에 기반한 6가지 특성 선택 기법을 적용하였다. 범주형 목표 변수와의 연관성을 평가하는 카이제곱 검정(Chi-squared test), 연속형 변수의 클래스 간 분산을 비교하는 ANOVA F-검정(f_{classif}), 변수 간의 비선형적 의존성까지 포착하는 상호정보량(Mutual Information) 기법을 활용하였다. 또한, 다중 검정 오류를 통제하기 위해 위양성률 통제(FPR), 위발견율 통제(FDR), 집단오류율 통제(FWE) 방식을 함께 적용하였다. 특성 선택을 전혀 수행하지 않은 조건(Raw)을 포함하여 총 7가지 조건을 비교한다.

3.5 분류 모델 및 성능 평가

본 연구는 M 피쳐의 결합 효과를 다각도로 분석하기 위해 선형 및 비선형 기계학습 모델 6종을 파이프라인의 최종 분류기로 구성하였다. 비교적 단순한 결정 경계를 가지는 K-최근접 이웃(KNN), 서포트 벡터 머신(SVM), 로지스틱 회귀(Logistic Regression)와 함께, 고차원 데이터 및 희소 행렬(Sparse Matrix) 처리에 강점이 있는 앙상블/부스팅 계열의 랜덤 포레스트(Random Forest), XGBoost, HGB(Histogram-based Gradient Boosting)를 평가 대상에 포함하였다. 특히 불균형 환경에서 소수 클래스 탐지력을 높이기 위해 검증 데이터 기반의 임계값 이동(Threshold Moving) 전략을 적용하였다.

파이프라인의 성능은 모델이 실제 불량을 놓치지 않고 탐지하는 능력을 최우선으로 고려하여 재현

'완다갔다는 내용을 지기'
중복내용?

을(Recall)과 F2-score를 핵심 평가지표로 사용하였다. 또한, 과도한 오탐(False Alarm)으로 인한 현장 적용성 저하를 방지하기 위해 진음성률(TNR)을 보조 지표로 모니터링하였다. 또한 실효성 있는 파이프라인의 선별을 위해 전체 924개 조합 중 $TNR \geq 0.5$ 및 $Recall \geq 0.6$ 을 동시에 만족하는 조합만을 'Surviving Pipeline'으로 정의하였다. $TNR \geq 0.5$ 는 모델이 정상 샘플의 절반 이상을 올바르게 구분하는 최소 수준으로, 이를 하회하는 모델은 사실상 정상 샘플 대부분을 불량으로 분류하는 극단적 편향 모델로 판단하여 제외하였다. $Recall \geq 0.6$ 은 실제 불량 샘플의 60% 이상을 탐지하는 최소 실용 수준으로, 반도체 공정에서 불량 미탐지(Type II Error)의 비용이 오탐(Type I Error)보다 큰 도메인 특성을 반영한 기준이다.

4. 실험 결과 및 분석

본 장에서는 전체 실험 조합 중 정상 샘플을 과

<Table 3> Setting key parameters by classification model

Model	Num. of neighbors	Kernel Function	Regularization Parameter	Max Num. of Iterations	Class weight	Num. of estimators	Learning rate	Max-Tree depth	Positive Class Weight
KNN	5 (Default)	N/A	N/A	N/A	N/A	N/A	N/A	N/A	N/A
SVM	N/A	RBF	1	N/A	N/A	N/A	N/A	N/A	N/A
Logistic Regression	N/A	N/A	1	10000	balanced	N/A	N/A	N/A	N/A
Random Forest	N/A	N/A	N/A	N/A	balanced	100	N/A	N/A	N/A
XGBoost	N/A	N/A	N/A	N/A	N/A	100	0.1	3	inverse class ratio : normal
HGB	N/A	N/A	N/A	100	balanced	N/A	0.1	None	N/A

도하게 불량으로 판단하는 극단적인 모델을 제외하기 위해 $TNR \geq 0.5$ 를 1차 필터 조건으로 적용하였으며, 이후 불량 검출 성능이 일정 수준 이상 확보된 조합만을 비교하기 위해 $Recall \geq 0.6$ 조건을 추가적으로 적용하였다. 해당 조건을 동시에 만족하는 surviving pipeline은 총 137개로 확인되었으며, 이를 기준으로 각 파이프라인 구성 요소별 성능 특성을 분석하였다.

4.1 실험 환경 및 하이퍼파라미터 설정

본 연구는 제안한 파이프라인의 객관적인 성능 평가와 데이터 누출 방지를 위해 모든 실험을 K-Fold(K=9) 교차 검증 구조 내에서 수행하였다. 각 전처리 단계 및 분류 모델의 하이퍼파라미터는 데이터 규모와 클래스 불균형 비율을 고려하여 설정하였다. 파이프라인 구성 요소 간 공정한 비교를 위해 하이퍼파라미터는 각 모델의 기본값 또는 불균형 대응에 최소한으로 필요한 값으로 고정하였

Table 크기 줄이고
줄간격이든. 이행게든.

으며, 본 연구는 모델 자체의 최적화보다 전처리 조합의 영향력 분석에 초점을 둔다.

결측치 대체 기법 중 평균 대체(Mean)는 각 훈련 폴드의 열별 평균값을 적용하였으며, In-painting KNN은 이웃 수(K)를 5로 설정하였다. 다중 대체 법인 MICE와 MissForest는 학습의 안정성을 위해 최대 반복 횟수(max_iter)를 10으로, MissForest 내부 랜덤 포레스트의 트리 수(n_estimators)는 100으로 고정하였다. 클래스 균형을 위한 SMOTE 역시 합성 샘플 생성 시 참조하는 이웃 수를 5로 설정하고, 훈련 집합 내 양불량 비율이 1:1이 되도록 지정하였다. 특성 선택 기법 중 단변량 통계 기반 기법(Chi2, f_classif, mutual_info)은 교차 검증 루프 내에서 최적의 특성 수를 탐색하였으며, 통계적 유의성 기반 기법(FPR, FDR, FWE)은 유의 수준(α)을 0.05로 일괄 고정하였다.

마지막으로 최종 분류기 6종에 대한 파라미터는 모델의 기본 특성을 반영하되 클래스 불균형에 대응하도록 구성하였다. 선형 모델(Logistic Regression, SVM)과 앙상블 모델(Random Forest, HGB)에는 클래스 빈도의 역수에 비례하는 class_weight='balanced' 가중치를 부여하였다.

XGBoost의 경우 각 폴드마다 '정상 샘플 수 / 불량 샘플 수'를 scale_pos_weight로 동적 계산하여 불량 클래스에 대한 손실 가중치를 상향 조정했다. 이와 함께 모델의 판정 임계값(0.5)을 그대로 사용할 경우 소수 클래스의 탐지 성능이 저하되는 것을 막고자, [0.01, 0.99] 구간을 0.01 단위로 탐색하여 검증 폴드 상에서 F2-score를 최대화하는 최적 임계값(Threshold Moving)을 도출하였다. 또한 SVM은 비선형 결정 경계를 효과적으로 학습하기 위해 RBF(Radial Basis Function) 커널을 적용하였으며, 정규화 파라미터(C)는 기본값인 1로 설정하였다. Logistic Regression은 클래스 불균형 환경에서도 최적화 과정이 충분히 수렴할 수 있도록 최대 반복 횟수(max_iter)를 10000으로 설정하였다. Random Forest와 XGBoost는 예측 안정성과 과적합 완화를 위해 트리 수(n_estimators)를 100으로 고정하였다. 특히 XGBoost는 안정적인 boosting 학습을 위해 학습률(learning_rate)을 0.1로 설정하고, 과도한 모델 복잡도를 방지하기 위해 최대 트리 깊이(max_depth)를 3으로 제한하였다. HGB(HistGradientBoosting)는 안정적인 수렴을 위해 max_iter=100, learning_rate=0.1을 적용하였다.

4.2 Imputation 방법별 성능 비교

본 절에서는 결측치 대체 방법에 따른 fault detection 성능 차이를 분석하였다. 해당 분석은 동일 imputation 조건을 공유하는 surviving pipeline들의 평균 성능을 비교한 것으로, 특정 조합의 단일 최고 성능을 비교한 후속 내용과는 분석 단위가 상이하다.

M_only 기반 조합 15개는 원 feature를 사용하지 않고 결측 여부 정보만을 사용하는 별도 분석 대상이므로, 본 절의 imputation 비교에서는 이를 제외하였다. 따라서 imputation 방법별 성능 비교는 원 feature 또는 원 feature+M을 사용하는 122개의 surviving pipeline을 대상으로 수행하였다

<Table 4> Top 3 Imputation Pipelines in Surviving Pipelines

	imputaion	F2	Recall	TNR
1	mean M	0.334005	0.679726	0.619807
2	missforest	0.325915	0.651090	0.628968
3	mean	0.323772	0.661742	0.614970

(Table 4와 같이 surviving pipeline을 2순위로 imputation pipeline별 성능을 비교한 결과, Mean_M 조합이 평균 F2-score 0.334005로 가장 높은 성능을 보였다. Mean_M은 Recall 0.679726, TNR 0.619807, AUROC 0.692427을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 안정적인 결과를 나타냈다. 이를 통해 먼저 단순 평균 대체 방식에 M feature를 추가하는 것이 일부 조건에서는 결측 정보의 보조적 효과를 통해 성능 향상에 기여하였음을 확인하였다. 두 번째로 높은 성능을 보인 MissForest는 평균 F2-score 0.325915, TNR 0.628968을 기록하였다. MissForest는 비선형적 변수 관계를 고려할 수 있는 결측 대체 방식으로, 본 실험에서도 정상 샘플 구분 성능 측면에서도 안정적으로 도출되었다. 세 번째로 높은 성능을 보인 Mean은 평균 F2-score 0.323772, Recall 0.661742, TNR 0.614970을 기록하였다. 해당 수치는 복잡한 결측 대체 방법이 항상 높은 성능을 보장하는 것은 아니며, 단순한 평균 대체 방식도 특정 feature selection 및 model 조합에서는 충분히 경쟁력 있는 성능을 낼 수 있을 것으로 추정된다.

종합적으로 surviving pipeline 기준에서는 Mean_M, MissForest, Mean이 상위 성능을 보였다. 특히 Mean_M이 가장 높은 평균 F2-score를 기록했다는 점은, M feature가 모든 조합에서 일관되게 효과적인 것은 아니지만, 특정 imputation 조건에서는 성능 향상에 기여할 것으로 기대된다.

4.3 SMOTE 적용여부에 따른 성능비교

본 절에서는 클래스 불균형 문제를 완화하기 위한 SMOTE 적용 여부가 fault detection 성능에 미치는 영향을 분석하였다.

<Table 5> Performance Comparison According to SMOTE Application in Surviving Pipelines

Balancing	F2	Recall	TNR
SMOTE	0.324959	0.668892	0.608121
RAW	0.321451	0.664437	0.609904

Table 5와 같이 SMOTE 적용 여부에 따른 성능을 비교한 결과, SMOTE를 적용한 조합은 평균 F2-score 0.324959로 Raw balancing 조합의 0.321451보다 소폭 높은 성능을 보였다. Recall 역시 SMOTE 적용 조합에서 0.668892로 나타나 Raw balancing의 0.664437보다 약간 높았다. 해당 결과는 소수 클래스인 불량 샘플을 보장하는 과정이 불량 검출 성능 향상에 일정 부분 기여했음을 의미한다.

다만 TNR은 SMOTE 적용 조합에서 0.608121, Raw balancing 조합에서 0.609904로 거의 유사하게 나타났다. 이는 $TNR \geq 0.5$ 및 $Recall \geq 0.6$ 조건을 통과한 조합만을 대상으로 할 경우, SMOTE 적용 여부에 따른 정상 샘플 구분 성능 차이가 크지 않음을 보여주었다.

종합적으로 SMOTE는 surviving pipeline 내에서 F2-score, Recall, AUC를 소폭 향상시키는 경향을 보였으나, 그 차이는 크지 않았다. 따라서 SMOTE는 불량 검출 성능 향상에 유효한 balancing 전략이지만, 성능 향상 폭은 imputation, feature selection, model 조합에 따라 제한적으로 나타나는 것으로 해석된다.

4.4 Feature selection 방법별 성능비교

본 절에서는 feature selection 방법에 따른 fault detection 성능 차이를 분석하였다.

<Table 6> Top 3 Feature Selection Strategies in Surviving Pipelines

	feature selection	F2	Recall	TNR
1	f_classif	0.346285	0.686957	0.639906
2	FPR	0.341559	0.665064	0.648465
3	Raw	0.322102	0.710652	0.569450

Table 6와 같이 surviving pipeline 기준으로 feature selection 방법별 성능을 비교한 결과, f_classif 기반 변수 선택 방식이 평균 F2-score 0.346285로 가장 높은 성능을 보였다. f_classif는 Recall 0.686957, TNR 0.639906, AUC 0.709859를 기록하여 불량 검출 성능과 정상 샘플 구분 성능 모두에서 비교적 안정적인 결과를 나타냈다. 두 번째로 높은 성능을 보인 FPR 방식은 평균 F2-score 0.341559를 기록하였으며, TNR은 0.648465로 상위 3개 방법 중 가장 높게 나타났다. 해당 결과는 FPR 기반 변수 선택이 불량 검출 성능을 유지하면서도 정상 샘플을 구분하는 데 비교적 효과적으로 작동했음을 의미한다. Raw는 별도의 feature selection을 적용하지 않은 기준 조합임에도 평균 F2-score 0.322102로 세 번째에 위치하였다. 특히 Recall은 0.710652로 가장 높게 나타났다. 이는 모든 변수를 유지하는 방식이 불량 샘플 탐지에는 유리하게 작용할 수 있음을 보여준다. 그러나 TNR은 0.569450으로 f_classif 및 FPR보다 낮아, 정상 샘플 오분류 가능성이 상대적으로 큰 것으로 해석된다. 실제 feature selection 기법만을 기준으로 보면 Raw를 제외하고 f_classif, FPR, mutual_info 순으로 높은 성능을 보였다. 그러나 전체 pipeline 구성 전략 관점에서는 Raw 역시 feature selection 미적용 기준선으로 의미가 있으며, 본 실험에서는 f_classif와 FPR이 F2-score와 TNR의 균형 측면에서 가장 안정적인 변수 선택 방식으로 확인되었다.

한국어로 쓰여진지) 명함은 한국어로 통일,
영어로 쓰여진

8page가 default
주절함 수.

4.5 모델별 성능비교

본 절에서는 머신러닝 모델에 따른 fault detection 성능 차이를 분석하였다.

<Table 7> Top 3 Models in Surviving Pipelines

	model	F2	Recall	TNR
1	KNN	0.334298	0.660882	0.636051
2	SVM	0.329818	0.696970	0.597553
3	RF	0.325396	0.666045	0.613900


Table 7과 같이 surviving pipeline 기준으로 모델별 평균 성능을 비교한 결과, KNN이 평균 F2-score 0.334298로 가장 높은 성능을 보였다. KNN은 Recall 0.660882, TNR 0.636051을 기록하여 불량 검출 성능과 정상 샘플 구분 성능 사이에서 비교적 균형 잡힌 결과를 나타냈다. KNN의 상대적 우위는 feature selection 단계를 거쳐 유효 변수 수가 축소된 환경에서 측정된 결과로, 고차원 원본 데이터에서의 일반적인 KNN 한계와는 상이한 조건임을 고려할 필요가 있다. 또한 KNN은 surviving pipeline 수가 상대적으로 적어, 특정 전처리 조합에서만 높은 성능을 보이는 경향이 있었다. 이는 특정 전처리 및 feature selection 조합에서 유사도 기반 분류 방식이 SECOM 데이터의 일부 구조를 효과적으로 반영했을 가능성을 보여준다. SVM은 평균 F2-score 0.329818로 두 번째에 위치하였으며, Recall은 0.696970으로 상위 3개 모델 중 가장 높게 나타났다. 이는 SVM이 불량 샘플을 탐지하는 데 상대적으로 민감하게 작동했음을 의미한다. 다만 TNR은 0.597553으로 KNN 및 RF보다 낮아, 정상 샘플 오분류 가능성은 상대적으로 큰 것으로 해석된다. RF는 평균 F2-score 0.325396으로 세 번째에 위치하였다. 그러나 RF는

surviving pipeline 수가 39개로 가장 많았다. 이는 RF가 특정 소수 조합에서만 우수한 것이 아니라, 다양한 imputation, balancing, feature selection 조건에서 안정적으로 필터 조건을 만족했음을 의미한다. 따라서 평균 F2-score 기준으로는 KNN과 SVM이 더 높게 나타났지만, 실험 전반의 안정성 측면에서는 RF 역시 중요한 후보 모델로 판단된다.

종합적으로 모델 비교 결과, KNN은 평균 F2-score 기준으로 가장 높은 성능을 보였고, SVM은 Recall 중심의 불량 검출 성능이 우수하였다. 반면 RF는 가장 많은 surviving pipeline을 형성하여 다양한 조건에서 안정적으로 작동하는 모델로 확인되었다.

4.6 M Feature 추가 효과 분석

상위 성능 조합들을 분석한 결과, 가장 높은 성능을 기록한 조합은 MICE / Raw / mutual_info / RF 조합으로 확인되었다. 이는 M feature의 추가가 모든 환경에서 항상 최고 성능으로 이어지는 것은 아님을 보여준다. 반면 surviving pipeline 중 두 번째로 높은 성능을 기록한 mean_M / SMOTE / fpr / HGB 조합은 M feature의 효과가 비교적 뚜렷하게 관찰된 대표 사례였다. 해당 조합은 동일 조건에서 M feature를 사용하지 않은 mean / SMOTE / fpr / HGB 조합과 비교하여 Recall 성능은 유지하면서 F2-score와 TNR이 동시에 향상되었다.



<Figure 2> Component-wise Performance Comparison in Surviving Pipelines (Top 3)

<Table 8> Representative Pipeline Showing the effect of M Feature

Pipeline	F2	Recall	TNR
Mean/SMOTE/FPR/HGB	0.361844	0.649495	0.700572
Mean_M/SMOTE/FPR/HGB	0.369538	0.649495	0.715725

Table 8과 같이 mean_M / SMOTE / fpr / HGB 조합은 M feature 추가 이후 Recall 성능 변화 없이 TNR과 F2-score가 향상된 대표적인 사례로 확인되었다. 특히 Recall이 유지된 상태에서 TNR이 증가하였다는 점은, 결측 지시자가 단순히 불량 예측을 공격적으로 증가시키는 것이 아니라 정상 샘플 구분에도 보조적인 정보를 제공했음을 시사한다. 즉 M feature는 독립적으로 강한 predictor라기보다 특정 preprocessing 및 모델 조합 환경에서 auxiliary signal로 작동할 가능성이 있는 것으로 해석된다. 또한 surviving 조합 중 M feature 추가 이후 F2-score가 상승한 조합은 총 36개로 확인되었다. 특히 mean_M / raw / fpr / RF, inpaintknn_M / raw / mutual_info / RF 조합에서도 비교적 뚜렷한 성능 향상이 관찰되었으며, missforest_M / SMOTE / raw / RF 조합의 경우 Recall 0.8586을 기록하여 불량 검출 측면에서 높은 성능을 보였다.

종합적으로 M feature는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 조합에서는 불량 검출 성능과 정상 샘플 구분 성능을 동시에 개선하는 효과를 보였다. 해당 결과는 결측 여부 정보가 단순히 제거되어야 하는 noise가 아니라 특정 환경에서는 공정 이상과 관련된 보조적 정보로 활용될 가능성이 있음을 시사한다.

4.7 최종 추천 파이프라인 조합

본 절에서는 앞서 정의한 surviving pipeline 조합 중 F2-score 기준 상위 3개의 파이프라인 조합을 최종 추천 조합으로 선정하였다. 앞선 4.2 ~ 4.5절의 구성 요소별 평균 비교와 달리, 본 절은 개별 파이프라인 단위의 절대 성능 기준으로 최종 조합을 선정한다.

<Table 9> Final Recommended Pipeline Combinations

Pipeline	F2	Recall	TNR
MICE/Raw/Mutual_Info/RF	0.388534	0.670707	0.727876
Mean_M/SMOTE/FPR/HGB	0.369538	0.649495	0.715725
MICE/SMOTE/FPR/RF	0.365989	0.694949	0.674059

Table 9와 같이 최종 추천 파이프라인 조합들은 surviving pipeline 중 F2-score 기준 상위권 성능을 기록한 조합들로 구성되었다. MICE / Raw / Mutual Information / RF 조합은 전체 조합 중 가장 높은 F2-score를 기록하여 전반적인 fault detection 성능 측면에서 가장 우수한 결과를 보였다. 반면 Mean_M / SMOTE / FPR / HGB 조합은 M feature 추가 효과가 비교적 뚜렷하게 관찰된 대표 사례였다. 해당 조합은 M feature를 사용하지 않은 동일 조건의 조합과 비교하여 Recall 성능 저하 없이 TNR과 F2-score가 동시에 향상되었다는 점에서 의미가 있었다. 또한 MICE / SMOTE / FPR / RF 조합은 세 조합 중 가장 높은 Recall 성능을 기록하였다. 해당 조합은 불량 샘플 검출 측면에서 비교적 우수한 성능을 보였음을 의미한다.

4.8 M_only 기반 결측 패턴 효과 분석


본 절에서는 원 feature를 제외하고 결측 여부만을 나타내는 M_only feature만을 사용하여 결측 fault detection 성능을 분석하였다. 이를 통해 결측 발생 패턴 자체가 공정 이상과 관련된 정보를 포함하고 있는지 확인하고자 하였다. 전체 137개의 surviving 조합 중 M_only 기반 조합은 총 15개로 확인되었다. 이는 전체 surviving 조합의 약 10.95%에 해당한다. 또한 M_only 기반 조합 중 최고 성능을 기록한 조합은 전체 pipeline 순위 기준 약 상위 50.5% 수준에 해당하였다. 이는 원 feature 없이 결측 여부 정보만 사용하였음에도 일부 조합에서 일정 수준 이상의 불량 검출 성능이 가능했음을 의미한다. M_only surviving 조합 15개를 분석한 결과, 모든 조합에서 SMOTE가 적용되지 않은 Raw balancing만 관찰되었다. 이는 M_only 기반 결측 패턴의 경우, synthetic oversampling을 적용하지 않은 상태에서도 Recall과 TNR 기준을 만족하는 조합이 존재했음을 보여

준다. Feature selection 측면에선 Chi2, F_classif, FPR이 각각 5회씩 동일하게 등장하였다. 즉 특정 feature selection 기법이 압도적으로 우세하게 나타나지는 않았으며, 여러 단일변수 기반 선택 기법에서 유사한 수준의 surviving 조합이 확인되었다.



<Figure 3> Feature Selection Distribution in Surviving M_only Pipelines

모델 측면에서도 XGBoost, Logistic Regression-(LR), KNN, HGB, RF가 각각 3회씩 동일하게 등장하였다. M_only 기반 surviving 조합이 특정 모델 하나에 집중되지 않고 다양한 모델 환경에서 비교적 고르게 관찰되었음을 확인할 수 있다.




<Figure 4> Model Distribution in Surviving M_only Pipelines

또한 성능 역시 특정 조합에서만 급격히 높아지기보다 비교적 안정적인 수준으로 분포하였다. 실제로 surviving M_only 조합의 F2-score는 평균 0.273635 수준으로 나타났으며, 최대값과 최소값 역시 각각 0.275256과 0.270354로 큰 차이를 보이지 않았다.

종합적으로 M_only 기반 조합은 전체 최고 성능 수준에는 도달하지 못하였으나, 원 feature 없이 결측 여부 정보만 사용하였음에도 일부 조합에서 $Recall \geq 0.6$ 및 $TNR \geq 0.5$ 조건을 만족하였다. M_only 기반 surviving 조합이 $Recall \geq 0.6$ 및 $TNR \geq 0.5$ 를 동시에 만족했다는 점은 주목할 만하다. 이는 모든 샘플을 정상으로 예측하는 경우 ($TNR=1.0$, $Recall=0$) 또는 모든 샘플을 불량으로 예측하는 경우 ($TNR=0$, $Recall=1.0$)와 같은 단순 편향 분류기로는 달성할 수 없는 수준으로, 원 공정 변수 없이 결측 여부 정보만으로도 일정 수준의 분류 정보가 내포되어 있음을 시사한다. 또한 surviving 조합이 특정 feature selection 기법이나 특정 모델에 편중되지 않았다는 점에서, 결측 패턴 자체가 fault detection에 활용 가능한 제한적인 보조 정보를 포함할 가능성을 시사한다. 따라서 M_only feature는 독립적인 핵심 predictor로 사용되기에는 한계가 있으나, 기존 공정 변수와 함께 사용될 경우 fault detection 성능을 보조하는 supplementary signal로 활용될 수 있다.

5. 결 론

본 연구에서는 결측치와 클래스 불균형이 동시에 존재하는 반도체 공정 데이터 환경에서 머신러닝 기반 fault detection 성능을 분석하기 위해 다양한 파이프라인 조합을 비교·평가하였다. 이를 위해 결측치 대체 방법, balancing 적용 여부, feature



<Figure 5> Supplementary Analysis and Key Findings

리벨한 반를 본에 인용.
Reference는 알라벳 순으로 정렬

selection 기법, 분류 모델을 조합한 총 924개의 파이프라인을 구성하였으며, SECOM 데이터셋을 기반으로 실험을 수행하였다.

실험 결과, 파이프라인 구성 요소에 따라 fault detection 성능 차이가 크게 나타났으며, 특히 MICE 기반 대치, f_{classif} 및 FPR 기반 feature selection, 그리고 Random Forest 계열 조합이 비교적 안정적인 성능을 보였다. 또한 SMOTE는 Recall 및 F2-score를 일부 향상시키는 경향을 나타냈으나, 그 효과는 다른 전처리 및 모델 조합에 따라 달라지는 것으로 확인되었다. 한편 본 연구에서는 결측 여부 자체를 나타내는 Missing Indicator(M feature)를 추가적으로 도입하여 결측 패턴의 정보적 활용 가능성을 분석하였다. 실험 결과, M feature는 모든 조합에서 일관된 성능 향상을 제공하지는 않았으나, 일부 조합에서는 Recall 저하 없이 TNR과 F2-score를 동시에 향상시키는 결과가 관찰되었다. 또한 M_only 기반 조합 역시 제한적이지만 일정 수준 이상의 fault detection 성능을 보였다. 이는 결측 정보가 단순한 노이즈가 아니라 특정 환경에서는 공정 이상과 관련된 보조적 신호로 활용될 가능성이 있음을 확인하였다.

본 연구는 반도체 공정의 결측 및 불균형 환경에서 머신러닝 파이프라인 구성 요소들의 성능 특성을 체계적으로 비교·분석하였다는 점에서 의의가 가진다. 또한 결측 패턴 자체의 활용 가능성을 실험적으로 검증함으로써, 향후 산업 공정 데이터 기반 fault detection 연구에서 결측 정보 활용에 대한 기초적 방향성을 제시하였다. 향후 연구에서는 실제 공정 환경에 보다 근접한 데이터셋을 활용하여 외부 검증을 수행하고, 결측 메커니즘 분석 및 딥러닝 기반 접근법과의 비교를 통해 결측 패턴 활용 가능성을 추가적으로 검증할 필요가 있다.

References

- 참고문헌들
본문에 모두 수록.
- [1] Salem, M., Taheri, S. and Yuan, J.S., An Experimental Evaluation of Fault Diagnosis from Imbalanced and Incomplete Data for Smart Semiconductor Manufacturing, Big Data and Cognitive Computing, 2018, Vol.2, No.4, Article 30.
 - [2] Susto, G.A., Schirru, A., Pampuri, S.,

McLoone, S. and Beghi, A., Machine Learning for Predictive Maintenance: A Multiple Classifier Approach, IEEE Transactions on Industrial Informatics, 2015, Vol.11, No.3, pp.812 - 820.

[3] Provost F., Machine Learning from Imbalanced Data Sets 101, Proceedings of the AAAI'2000 Workshop on Imbalanced Data Sets, AAAI Technical Report WS-00-05, 2000, pp. 1 - 3.

[4] McCann, M. and Johnston, A., SECOM Dataset: Data from a Semiconductor Manufacturing Process, UCI Machine Learning Repository, 2008.

[5] Rubin, D.B., Inference and Missing Data, Biometrika, 1976, Vol.63, No.3, pp.581 - 592.

[6] Saar-Tsechansky M., Provost F., Handling Missing Values When Applying Classification Models, Journal of Machine Learning Research, Vol. 8, 2007, pp. 1623 - 1657.

[7] Sperrin M., Martin G.P., Sisk R., Peek N., Missing Data Should Be Handled Differently for Prediction Than for Description or Causal Explanation, Journal of Clinical Epidemiology, Vol. 125, 2020, pp. 183 - 187.

[8] Van Ness M., Bosschieter T.M., Halpin-Gregorio R., Udell M., The Missing Indicator Method: From Low to High Dimensions, arXiv preprint arXiv:2211.09259, 2022.

[9] Oliver Urs Lenz, Daniel Peralta, Chris Cornelis, No imputation without Representation arXiv preprint arXiv:2206.14254v4, 2024

[10] Lee et al. , A data-driven approach to selection of critical process steps in the semiconductor manufacturing process considering missing and imbalanced data, Journal of Manufacturing Systems, Vol. 52, Part A, pp. 146 -156, 2019

[11] Fan, An Interdisciplinary and Cross-Task Review on Missing Data Imputation, arXiv preprint, arXiv:2511.01196., 2025

[12] Shao et al., A Survey on Missing Data Generation in Networks, Mathematics, 2026, 14(2), Article 341

- [13] Zhang et al., DiffPuter: Empowering Diffusion Models for Missing Data Imputation, ICLR 2025 Spotlight, OpenReview
- [14] Zhang et al., How to manage missing covariates in randomized controlled trials: a comparison of strategies, BMC Medical Research Methodology, 2025
- [15] Ehrig et al. Imputation and Missing Indicators for Handling Missing Longitudinal Data: Data Simulation Analysis Based on Electronic Health Record Data, JMIR Medical Informatics, 2025
- [16] Le Morvan et al. , Imputation for prediction: beware of diminishing returns, arXiv:2407.19804, 2025
- [17] Paterakis et al. , Do We Really Need Imputation in AutoML Predictive Modeling?, ACM Transactions on Knowledge Discovery from Data, 18(6), 2024
- [18] Pereira et al. , Imputation of Data Missing Not at Random: Artificial Generation and Benchmark Analysis, Expert Systems with Applications, Vol. 249, Article 123654, 2024
- [19] Park et al. , Study on Data Preprocessing for Machine Learning Based on Semiconductor Manufacturing Processes, Sensors, 2024, 24(17), 5461, 2024
- [20] Farrag et al. , Rare Class Prediction Model for Smart Industry in Semiconductor Manufacturing, arXiv preprint, arXiv:2406.04533, 2024
- [21] Digitale et al. , Methods for Addressing Missingness in Electronic Health Record Data for Clinical Prediction Models, JMIR Medical Informatics, 2025
- [22] Khan et al. , Still More Shades of Null: A Benchmark for Responsible Missing Value Imputation, arXiv preprint, arXiv:2409.07510, 2024
- [23] Gorla et al. , CACTI: Leveraging Copy Masking and Contextual Information to Improve Tabular Data Imputation, ICML 2025, Proceedings of Machine Learning Research, Vol. 267, pp. 20187–20225, 2025
- [24] Du et al. , ReMasker: Imputing Tabular Data with Masked Autoencoding, arXiv: 2309.13793, 2024
- [25] Chang et al. , MFAN Learning on Missing Tabular Data: Attention with Self-Supervision, Not Imputation, is All You Need, ACM Transactions on Intelligent Systems and Technology, 2025, 16(3), Article 73, 2025
- [26] Caruso et al. , Not Another Imputation Method: A Transformer-based Model for Missing Values in Tabular Datasets, arXiv preprint, arXiv:2407.11540, 2025
- [27] Samad et al. , No Imputation of Missing Values in Tabular Data Classification Using Incremental Learning, arXiv preprint, arXiv:2504.14610, 2025
- [28] Feitelberg et al. , TabImpute: Accurate and Fast Zero-Shot Missing-Data Imputation with a Pre-Trained Transformer, arXiv preprint, arXiv:2510.02625, 2025
- [29] Zhang et al. , Federated Incomplete Tabular Data Prediction with Missing Complementarity, Proceedings of the VLDB Endowment, 2025, 18(10), pp. 3531–3544, 2025
- [30] Toye et al. , Benchmarking Missing Data Imputation Methods for Time Series Using Real-World Test Cases, Proceedings of Machine Learning Research, Vol. 287, pp. 480–501; CHIL 2025
- [31] Chen et al. , Rethinking the Diffusion Models for Missing Data Imputation: A Gradient Flow Perspective, NeurIPS 2024, Advances in Neural Information Processing Systems 37, 2024